Übungsblatt: Entscheidungsbäume (Decision Tree Learner DTL)

Carsten Gips (HSBI)

1 Bonus: Starke vs. Schwache KI (2P)

Recherchieren Sie und diskutieren Sie folgende Punkte:

- Ist ein System wie ChatGPT "intelligent"? Was ist der Kern des Systems?
- Gibt es Systeme, die intelligent sind? Was tun diese, wie arbeiten sie?
- Brauchen wir wirklich Intelligenz in Systemen? Reicht auch schwache KI, d.h. reichen intelligent *wirkende* Systeme?
- Absicht vs. Auswirkung: vorteilhafte Anwendungen vs. Unfälle (Robustheit und falsche Korrelationen, Fairness, Sicherheit) vs. Missbrauch (Spam, Betrug, Spear-Phishing, Desinformation) vs. doppelte Verwendung ("*dual use*": Raketen, Kernkraft, Genbearbeitung, ...) vs. *Bias* (Voreingenommenheit)

Thema: Schwache vs. starke KI, Auswirkungen und Nutzen

2 DTL.01: Entscheidungsbäume mit CAL3 und ID3 (6P)

Es ist wieder Wahlkampf: Zwei Kandidaten O und M bewerben sich um die Kanzlerschaft. Die folgende Tabelle zeigt die Präferenzen von sieben Wählern.

Nr.	Alter	Einkommen	Bildung	Kandidat
1	≥ 35	hoch	Abitur	O
2	< 35	niedrig	Master	O
3	≥ 35	hoch	Bachelor	M
4	≥ 35	niedrig	Abitur	M
5	≥ 35	hoch	Master	O
6	< 35	hoch	Bachelor	O
7	< 35	niedrig	Abitur	M

Trainieren Sie nacheinander mit den Verfahren CAL3 (3P) und ID3 (3P) auf der obigen Trainingsmenge je einen Entscheidungsbaum. Nutzen Sie für CAL3 dabei die Schwellen $S_1 = 4$ und $S_2 = 0.7$.

Sie können dafür eine Handsimulation anwenden oder die Algorithmen implementieren. Sie können gern auch die Java-Klassen im Paket `aima.core.learning` bzw. die Python-Klassen in `learning.py` als Ausgangspunkt nutzen.[1]

3 DTL.02: Pruning (1P)

Vereinfachen Sie schrittweise den Baum

[1] Im Python-Code tauchen immer wieder "TODO"-Marker auf - bitte mit Vorsicht genießen!

$$x_3(x_2(x_1(C, A), x_1(B, A)), x_1(x_2(C, B), A))$$

so weit wie möglich.

Nutzen Sie die linearisierte Schreibweise. Geben Sie die jeweils verwendete Regel an.

Thema: Anwendung der Transformations- und Pruning-Regeln

4 DTL.03: Machine Learning mit Weka (3P)

Weka (waikato.github.io/weka-wiki/) ist eine beliebte Sammlung von (in Java implementierten) Algorithmen aus dem Bereich des Maschinellen Lernens. Laden Sie sich das Tool in der aktuellen stabilen Version herunter und machen Sie sich mit der beiliegenden Dokumentation vertraut.

Laden Sie sich die Beispieldatensätze "Zoo" (`zoo.csv`) und "Restaurant" (`restaurant.csv`) aus dem AIMA-Repository (github.com/aimacode/aima-data) herunter.[2] Zum Laden der Beispieldatensätze in Weka müssen die `.csv`-Dateien eine Kopfzeile mit den Namen der Attribute haben. Passen Sie die Dateien entsprechend an und laden Sie diese im Reiter "Pre-Process" mit "Open file ...".

Hinweis: Wenn Sie *Weka 3.6* einsetzen, sind alle für dieses Blatt erforderlichen Algorithmen bereits vorhanden. In neueren Versionen müssen Sie in der Weka-Haupt-GUI den Paketmanager unter "Tools" starten und dort nach einem Paket suchen, welches ID3 enthält, und dieses Paket nachinstallieren.

1. Training mit J48 (1P)

   Wechseln Sie auf den Reiter "Classify" und wählen Sie mit dem Button "Choose" den Entscheidungsbaum-Lerner J48 aus. (Dies ist eine Java-Implementierung von C4.5. Die ID3-Implementierung funktioniert für den `zoo.csv`-Datensatz leider nicht ...)

   Lernen Sie für die beiden Datensätze je einen Entscheidungsbaum. Wie sehen die Bäume aus? Wie hoch ist jeweils die Fehlerrate für den Trainingssatz? (Stellen Sie unter "Test options" den Haken auf "Use training set".) Interpretieren Sie die **Confusion Matrix**.

2. ARFF-Format (1P)

   Lesen Sie in der beiliegenden Doku zum Thema "ARFF" nach. Dabei handelt es sich um ein spezielles Datenformat, womit man Weka mitteilen kann, welche Attribute es gibt und welchen Typ diese haben und welche Werte auftreten dürfen. (Link)

   Erklären Sie die Unterschiede zwischen "nominal", "ordinal" (bzw. "numeric") und "string".

   Konvertieren Sie den Zoo- und Restaurantdatensatz in das ARFF-Format. Beachten Sie, dass die ID3-Implementierung von Weka nicht mit bestimmten Attributtypen umgehen kann.

3. Training mit ID3 und J48 (1P)

   Trainieren Sie für die im letzten Schritt erstellten Datensätze (Zoo und Restaurant) im ARFF-Format erneut Entscheidungsbäume. Nutzen Sie diesmal sowohl ID3 als auch J48.

[2] Zum Zoo-Datensatz gibt es die Erklärung direkt im Repo, für den Restaurant-Datensatz finden Sie die Erklärung im AIMA (Buch).

Vergleichen Sie wieder die Ergebnisse (Entscheidungsbäume, Fehlerraten, Confusion Matrix) untereinander und mit den Ergebnissen aus dem J48-Lauf mit den `.csv`-Dateien.

Thema: Kennenlernen von Weka

Unless otherwise noted, this work is licensed under CC BY-SA 4.0.

> **Last modified:** 12d767c (homework: spread the discussion tasks across the first four exercise sheets, 2025-09-15)