# Übungsblatt: Lineare / Logistische Regression & Gradientenabstieg

Canan Yıldız (Türkisch-Deutsche Universität)

# 1 NN.Regression.01: Lineare Regression & Gradientenabstieg (3P)

Es sind folgende Trainingsdaten gegeben:

$$(x^{(1)}, y^{(1)}) = (1, 1), (x^{(2)}, y^{(2)}) = (2, 1), (x^{(3)}, y^{(3)}) = (3, 2)$$

Es soll das lineare Regressionsmodell $h(x) = w_0 + w_1 x$ mit diesen Daten trainiert werden, wobei die zu minimierende Kostenfunktion (durchschnittliche Summe der Fehlerquadrate) wie folgt gegeben ist:

$$J(\mathbf{w}) = \frac{1}{2m} \sum_{j=1}^{m} (h(x^{(j)}) - y^{(j)})^2$$

- (1P) Geben Sie $n$ und $m$ an und schreiben Sie die Kostenfunktion für die gegebenen Datenpunkte explizit auf. Berechnen Sie den Gradientenvektor $\nabla J$ und beschreiben Sie die Bedeutung dieses Vektors.
- (2P) Seien die Gewichte in einem Iterationsschritt $w_0 = 1, w_1 = 1$. Führen Sie für die Lernraten $\alpha = 0.01$, $\alpha = 0.1$ und $\alpha = 1$ jeweils fünf aufeinanderfolgende Iterationen des Gradientenabstieg (Gradient Descent) Algorithmus durch.

  Erstellen Sie eine Tabelle mit den Spalten $w_0, w_1, J(\mathbf{w}), \nabla J(\mathbf{w}), \alpha \cdot \nabla J(\mathbf{w})$ und notieren Sie die zugehörigen Werte für jede Iteration. Erklären Sie, wie die Gewichtsaktualisierungen durchgeführt werden und geben Sie die dafür verwendete Formel an.

  Wie verändern sich die Kosten während des Gradientenabstieges für die unterschiedlichen Lernraten? Begründen Sie dieses Verhalten.

  Sie können das folgende **Geogebra-Arbeitsblatt** zu Hilfe nehmen.

*Thema*: Verständnis und Ablauf Gradientenabstieg und Lernrate

# 2 NN.Regression.02: Logistische Regression & Gradientenabstieg (7P)

## 2.1 Datensatz (1P)

- Konstruieren Sie Ihren eigenen Datensatz $\mathcal{D}$ mit $m = 100$ gleichförmig verteilten Zufallspunkten aus dem Bereich $\mathcal{X} = [-1, 1] \times [-1, 1]$.
- Wählen Sie auf ähnliche Weise zwei zufällige, gleichmäßig verteilte Punkte aus dem Bereich $[-1, 1] \times [-1, 1]$. Verwenden Sie die Gerade, die durch diese zwei Punkte verläuft, als die Entscheidungsgrenze Ihrer Zielfunktion $f$. Sie können die positiv beschriftete Seite beliebig festlegen.
- Werten Sie die Zielfunktion für jeden Datenpunkt $\mathbf{x}^{(j)}$ aus, um die entsprechenden Beschriftungen (Ausgangslabel) $y^{(j)}$ zu erhalten.

## 2.2 Training (3P)

Trainieren Sie ein logistisches Regressionsmodell auf diesen Daten, um $h^* = \sigma(w^T x)$ zu finden. Verwenden Sie dazu den Gradientenabstieg-Algorithmus. Initialisieren Sie alle Gewichtswerte mit 0 und führen Sie 2000 Iterationen durch. Nehmen Sie $\alpha = 0.1$ als Lernrate. Speichern Sie alle 100 Schritte die berechneten Kosten. Zeichnen Sie am Ende die Kosten als Diagramm über die Anzahl der Iterationen auf.

## 2.3 Experimente (3P)

Wiederholen Sie das obige Experiment mit unterschiedlichen Lernraten, z.B. $\alpha = 0.1$, $\alpha = 0.01$ und $\alpha = 0.001$. Vergleichen Sie die Kosten-Diagramme.

Sie können das folgende **Jupyter Notebook** als Startpunkt benutzen. Sie können alternativ auch eine andere Programmiersprache und/oder einen anderen Datensatz (z.B. zufällig generierter Datensatz mittels Numpy and Scikit-Learn) verwenden.

*Thema*: Verständnis und Implementierung Logistische Regression

Unless otherwise noted, this work is licensed under CC BY-SA 4.0.

> **Last modified:** c6e3966 (lecture: fix utf8 issues (pdf), 2025-07-24)