DTL: Machine Learning 101

Carsten Gips (HSBI)

TL;DR
Lernen wird in der KI oft als Verhaltensänderung (eines Systems) aufgefasst. Dabei soll eine Gütefunktion optimiert werden.
Je nach verfügbarem Feedback eines "Lehrers" werden typischerweise drei Arten von Lernen unterschieden: Überwachtes Lernen, Unüberwachtes Lernen, Reinforcement Lernen. Dabei stellt der Lehrer beim überwachten Lernen Trainingsbeispiele plus eine Vorgabe (Klasse, Funktionswert) zur Verfügung, während beim unüberwachten Lernen nur die Trainingsbeispiele bereitgestellt werden und der Algorithmus selbst Zusammenhänge in den Daten erkennen soll. Beim Reinforcement Learning erfolgt das Feedback am Ende einer Kette von Aktionen, d.h. der Algorithmus muss diese Bewertung auf die einzelnen Aktionen zurückrechnen.
Beim überwachten Lernen soll eine Hypothese aufgebaut werden, die der echten (zu lernenden) Funktion möglichst nahe kommt. Eine konsistente Hypothese erklärt die Trainingsdaten, eine generalisierende Hypothese kann auch unbekannte Daten (die aus der selben Quelle stammen, also zum selben Problem gehören) korrekt bewerten. Es wird unterschieden zwischen Klassifikation (einige wenige diskrete Label/Klassen, die den Trainingsbeispielen zugeordnet sind) und Regression (Lernen eines Funktionsverlaufs).
Merkmalsvektoren gruppieren Eigenschaften des Problems bzw. der Objekte, d.h. jedes Objekt kann über einen Merkmalsvektor beschrieben werden. Trainingsdaten sind ausgewählte Beispielobjekte (durch Merkmalsvektoren beschrieben) plus die Vorgabe (Klasse oder Funktionswert) vom Lehrer.

Videos

- VL Machine Learning 101

1 Was ist Lernen?

> Verhaltensänderung eines Agenten in Richtung der Optimierung eines Gütefunktionals (Bewertungsfunktion) durch Erfahrung.

2 Warum Lernen?

- Nicht alle Situationen vorhersehbar
- Nicht alle Details modellierbar
- Lösung oder Lösungsweg unbekannt, nicht explizit programmierbar
- Data Mining: Entdeckung neuen Wissens durch Analyse der Daten
- Selbstanpassende Programme

=> Lernen wichtige Eigenschaft lebender Wesen :-)

3 Learning Agent

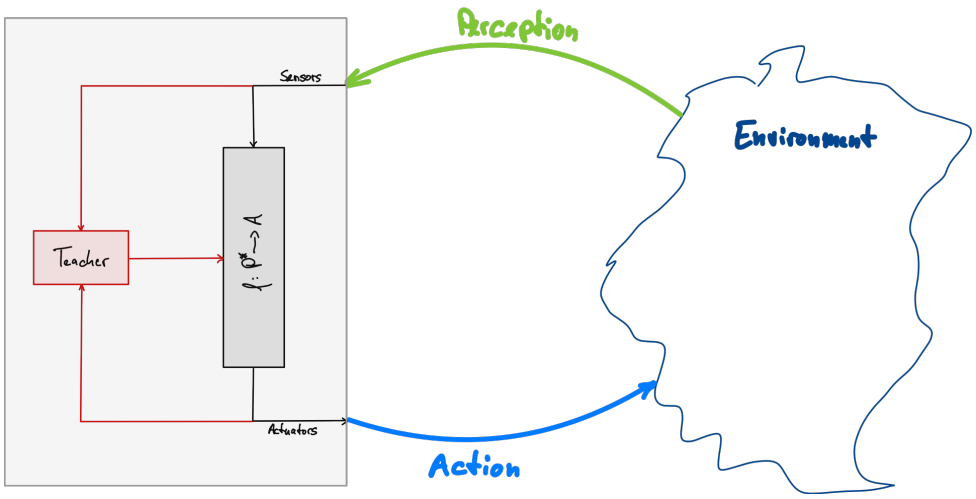

4 Feedback während des Lernens

- **Überwachtes Lernen**
  - Lernen durch Beobachtung
  - Vorgabe von Beispielen: Ein- und Ausgabewerte

  => Regression, Klassifikation

- **Unüberwachtes Lernen**
  - Erkennen von Mustern in den Inputdaten, Clustering
  - Kein Feedback (!)

- **Reinforcement Lernen**
  - Bewertung der Aktionen des Agenten am Ende einer Aktionsfolge

Beispiel Kleinkind: Lernen von Klassen/Konzepten durch Beispiele

- Zuerst ist alles “Katze” (Übergeneralisierung)
- Differenzierung durch Feedback der Umwelt; Erkennung unterschiedlicher Ausprägungen

5 Beispiel: Kreditrisiko

- Bankkunde beantragt Kredit
- Soll er aus Sicht der Bank den Kredit bekommen?

- Bankangestellter betrachtet (relevante) Merkmale des Kunden:
  - Alter, Einkommen, sozialer Status
  - Kundenhistorie bei der Bank
  - Höhe des Kredits

- Bewertung des Kreditrisikos:
  - **Klassifikation**: Guter oder schlechter Kunde (Binäre Entscheidung: 2 Klassen)
  - **Regression**: Vorhersage Gewinn/Verlust für die Bank (Höhe des Gewinns/Verlusts interessant)

6 Beispiel: Autoreparatur

- **Gegeben**: Eigenschaften eines Autos

  => Eigenschaften: Ausprägungen der Merkmale

- **Gesucht**: Diagnose und Reparaturanleitung

  => Hypothese über den Merkmalen (Funktion h)

7 Lernen durch Beobachten: Lernen einer Funktion f

Funktionsapproximation: Lernen einer Funktion f anhand von Beispielen

- Ein Beispiel ist ein Tupel $(\mathbf{x}, \mathrm{f}(\mathbf{x}))$, etwa

$$(\mathbf{x}, \mathrm{f}(\mathbf{x})) = \begin{pmatrix} O & O & X & \\ . & X & . & ,+1 \\ X & . & . & \end{pmatrix}$$

- Aufgabe: Baue Hypothese h auf, so dass h $\approx$ f.
  - Benutze dazu Menge von Beispielen => **Trainingsdaten**.

- Ziele:
  1. **Konsistente Hypothese**: Übereinstimmung bei Trainingsdaten
  2. **Generalisierende Hypothese**: Korrekte Vorhersage bei unbekannten Daten

Anmerkung: Stark vereinfachtes Modell realen Lernens!

8 Konstruieren einer konsistenten Hypothese

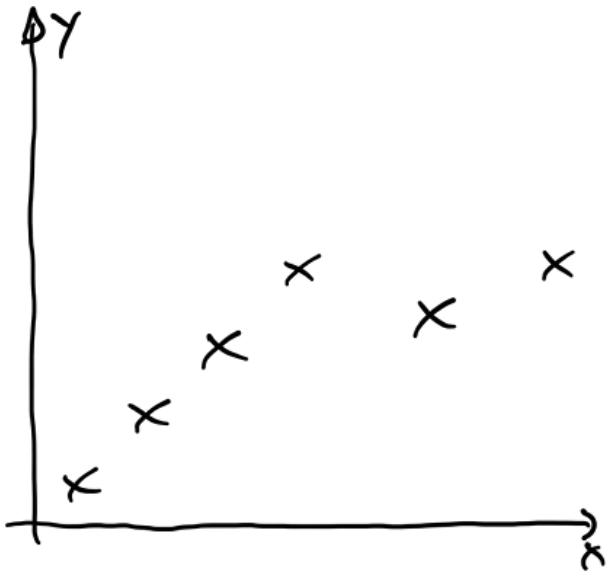

Welcher Zusammenhang ist hier dargestellt? Offenbar eine Art Funktionsverlauf … Wir haben für einige x-Werte die zugehörigen y-Werte vorgegeben.

9 Konstruieren einer konsistenten Hypothese (cnt.)

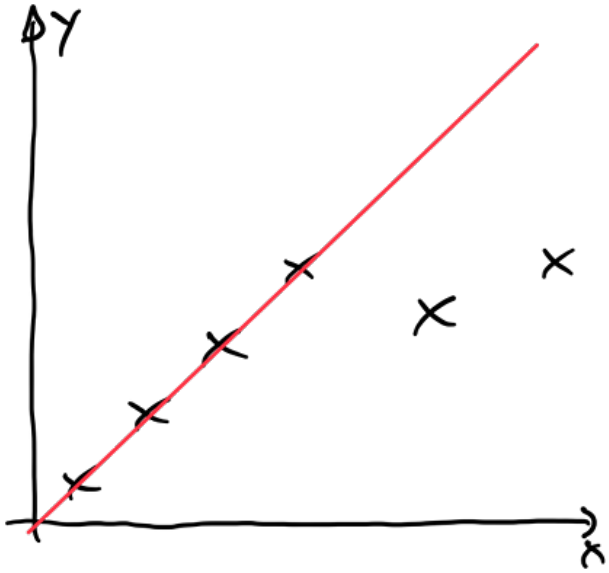

Die einfachste Approximation wäre eine lineare Funktion. Allerdings werden hierbei einige Werte mehr oder weniger stark nicht korrekt widergegeben, d.h. man hat einen relativ hohen (Trainings-) Fehler.

10 Konstruieren einer konsistenten Hypothese (cnt.)

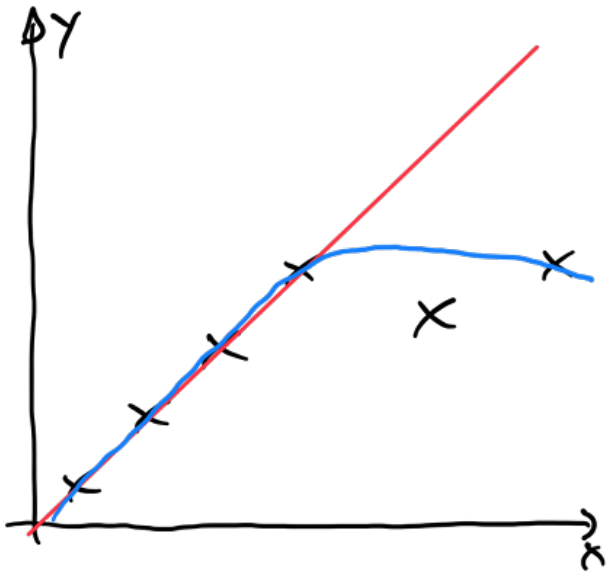

Die Hyperbel erklärt die Trainingsdaten bis auf den einen Punkt sehr gut. Die Frage ist, ob dieser eine Punkt zum zu lernenden Zusammenhang gehört oder ein Ausreißer ist, den man gefahrlos ignorieren kann?

11 Konstruieren einer konsistenten Hypothese (cnt.)

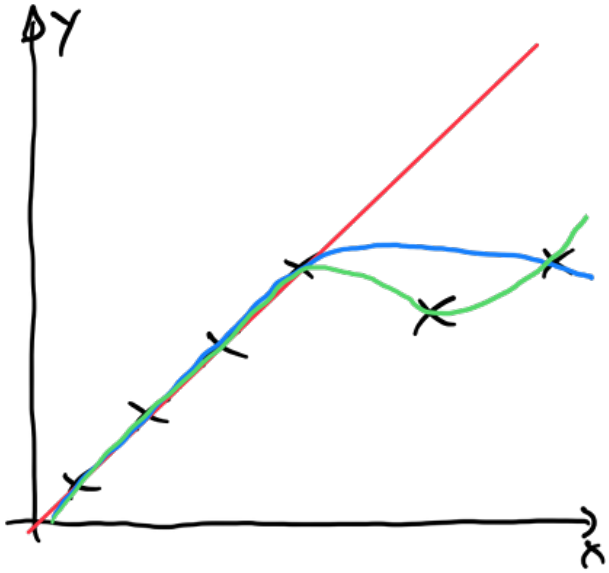

Die grüne Hypothese ist von allen bisher gezeigten die komplexeste, erklärt aber alle Datenpunkte. D.h. hier wäre der Trainingsfehler Null. Zwischen den Trainingsdaten zeigt das Modell eine “glatte” Approximation, d.h. es wird

auch neue Daten, die es beim Training nicht gesehen hat, relativ gut erklären. (Dabei liegt freilich die Annahme zugrunde, dass alle relevanten Daten in der Trainingsmenge vorhanden sind, d.h. dass es insbesondere zwischen den Datenpunkten keine Ausreißer o.ä. gibt.)

12 Konstruieren einer konsistenten Hypothese (cnt.)

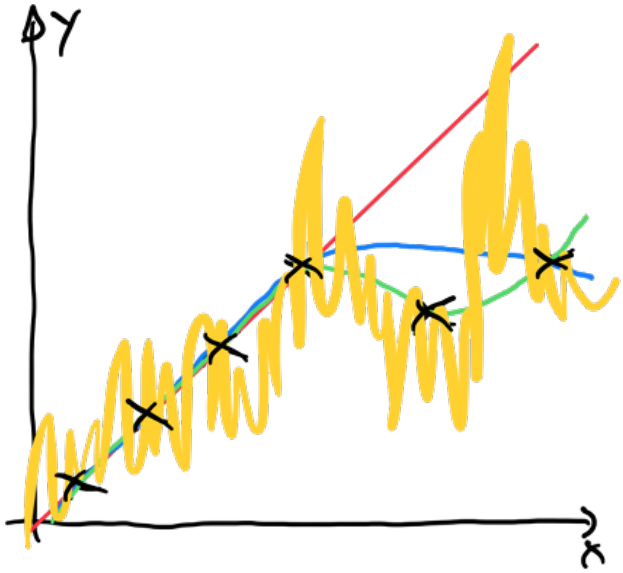

Diese Hypothese erklärt ebenfalls sämtliche Trainingsdaten. Allerdings schwingt die Funktion zwischen den Daten stark hin und her. Vermutlich entspricht dies nicht dem zu lernenden Funktionsverlauf. Der Trainingsfehler wäre wie bei der deutlich einfacheren Hypthese aus dem letzten Schritt Null. Der Generalisierungsfehler (sprich die Abweichung, wenn man das Modell nach Daten zwischen den Trainingspunkten fragt) dürfte erheblich höher liegen.

D.h. hier hat das Modell einfach die Trainingsdaten auswendig gelernt, aber nicht den Zusammenhang zwischen den Daten! Dies ist in der Regel unerwünscht!

13 Occam's Razor

Bevorzuge die einfachste konsistente Hypothese!

1. Wenn es mehrere mögliche Erklärungen für einen Sachverhalt gibt, ist die einfachste Erklärung allen anderen vorzuziehen.
2. Eine Erklärung ist "einfach", wenn sie möglichst wenige Variablen und Annahmen enthält und wenn diese in klaren logischen Beziehungen zueinander stehen, aus denen der zu erklärende Sachverhalt logisch folgt.

14 Trainingsdaten und Merkmalsvektoren

Lehrer gibt Beispiele vor: Eingabe $\mathbf{x}$ und passende Ausgabe f$(\mathbf{x})$

- Ausgabe: typischerweise Skalar (Funktionswert oder Klasse)
  => Beispiel: Bewertung eines Spielstandes bei TicTacToe

- Eingabe: (Beschreibung des) Objekt(s) oder Situation, die zur Ausgabe gehört
  => Beispiel: Spielstand bei TicTacToe

Merkmalsvektoren:

- Zusammenfassen der relevanten Merkmale zu Vektoren

15 Beispiel: Schwimmen im See

Beschreibung der Faktoren, wann ich im See schwimmen möchte:

1. Scheint die Sonne?
2. Wie warm ist das Wasser?
3. Wie warm ist die Luft?

- Trainingsbeispiel:
  - Eingabe: Merkmalsvektor (`sonnig`, `warm`, `warm`)
  - Ausgabe: Klasse `ja`

Dabei wird davon ausgegangen, dass jeder Faktor (jedes Merkmal) an einer bestimmten Stelle im Merkmalsvektor aufgeführt ist. Beispielsweise gehört das `sonnig` zur Frage "Scheint die Sonne", `warm` jeweils zur Wasser- und zur Lufttemperatur.

Damit hat man in einem Vektor eine Situation komplett beschrieben, d.h. einen Zustand der Welt mit den relevanten Dingen beschrieben. Diesem Zustand kann man beispielsweise ein Label (Klasse) verpassen, hier in diesem Fall "ja, in dieser Welt möchte ich schwimmen".

Die Trainingsmenge baut sich dann beim überwachten Lernen aus vielen solcher Paare (Merkmalsvektor, Klasse) auf, und die Algorithmen sollen diese Zuordnung lernen, d.h. ein Modell für diese Daten erzeugen, welches die Daten gut erklärt und darüber hinaus für neue Daten aus der selben Datenquelle gute Vorhersagen macht.

16 Trainingsdaten – Merkmalsvektoren

Generell: Merkmalsvektor für Objekt v:

$$\mathbf{x}(v) = (x_1, x_2, \ldots, x_n)$$

- n Merkmale (Attribute)
- Attribut x_t hat m_t mögliche Ausprägungen
- Ausprägung von v bzgl. x_t: $\quad x_t(v) = i \quad$ (mit $i = 1 \ldots m_t$)

Anmerkung: Stellen Sie sich den Merkmalsvektor $\mathbf{x}$ vielleicht wie einen Konstruktor einer Klasse x vor: Die einzelnen Attribute x_t sind die Parameter, aus denen der Merkmalsvektor aufgebaut ist/wird. Jedes der Attribute hat einen Typ und damit eine bestimmte Anzahl erlaubter Werte ("Ausprägungen") …

Trainingsbeispiel:

- Tupel aus Merkmalsvektor und zugehöriger Klasse: $(\mathbf{x}(v), k)$

17 Wrap-Up

- Lernen ist Verhaltensänderung, Ziel: Optimierung einer Gütefunktion
  - Aufbau einer Hypothese, die beobachtete Daten erklären soll
  - Arten: Überwachtes Lernen, Unüberwachtes Lernen, Reinforcement Lernen
- Merkmalsvektoren gruppieren Eigenschaften des Problems bzw. der Objekte
- Trainingsdaten: Beispielobjekte (durch Merkmalsvektoren beschrieben) plus Vorgabe vom Lehrer

18 Zum Nachlesen

- Russell und Norvig (2021): Lernen: Abschnitte 19.1 und 19.2

Lernziele

- k1: Ich kann den Begriff "(maschinelles) Lernen" definieren und verschiedene Arten unterscheiden
- k2: Ich kann "Überwachtes Lernen" erklären: Lernen durch Beobachten (mit Lehrer)
- k2: Ich kann wichtige Elemente des (maschinellen) Lernens erklären: Merkmalsvektoren, Eigenschaften, Ausprägung, Objekte, Trainingsmenge

Quizzes

- Selbsttest Intro ML (ILIAS)

Challenges

Modellierung

Sie stehen vor der Entscheidung, ob Sie sich zur Vorbereitung auf die Flipped-Classroom-Sitzung noch das Skript anschauen. Welche Attribute benötigen Sie, um die Situation zu beschreiben?

Metriken für Klassifikatoren

Es ist wieder Wahlkampf: Zwei Kandidaten O und M bewerben sich um die Kanzlerschaft. Die folgende Tabelle zeigt die Präferenzen von sieben Wählern.

Nr.	Alter	Einkommen	Bildung	Kandidat	Vorhersage
1	≥ 35	hoch	Abitur	O	O
2	< 35	niedrig	Master	O	O
3	≥ 35	hoch	Bachelor	M	M
4	≥ 35	niedrig	Abitur	M	M
5	≥ 35	hoch	Master	O	O
6	< 35	hoch	Bachelor	O	M
7	< 35	niedrig	Abitur	M	O

Auf diesem Datensatz wurde ein Klassifikator trainiert, die Trainingsergebnisse sind in der Tabelle unter “Vorhersage” angegeben.
Bewerten Sie den Klassifikator.

Quellen

Russell, S., und P. Norvig. 2021. *Artificial Intelligence: A Modern Approach*. 4th Edition. Pearson. http://aima.cs.berkeley.edu.

Unless otherwise noted, this work is licensed under CC BY-SA 4.0.

> **Last modified:** f393f68 (lecture: fix publishing year of AIMA, 2025-09-27)