DTL: CAL2

Carsten Gips (HSBI)

TL;DR
Eine Hypothese kann im einfachsten Fall als Entscheidungsbaum dargestellt werden. Die Merkmale bilden dabei die Knoten im Baum, und je Ausprägung gibt es eine Kante zu einem Nachfolgerknoten. Ein Merkmal bildet die Wurzel des Baums, an den Blättern sind die Klassen zugeordnet.
Einen Entscheidungsbaum kann man zur Klassifikation eines Objekts schrittweise durchlaufen: Für jeden Knoten fragt man die Ausprägung des Merkmals im Objekt ab und wählt den passenden Ausgang aus dem Knoten. Wenn man am Blatt angekommen ist, hat man die Antwort des Baumes auf das Objekt, d.h. üblicherweise die Klasse.
Den Baum kann man mit dem Algorithmus CAL2 schrittweise aufbauen. Man startet mit "Nichtwissen" (symbolisiert mit einem "*") und iteriert durch alle Trainingsbeispiele, bis der Baum sich nicht mehr verändert. Wenn der Baum auf ein Beispiel einen "*" ausgibt, dann ersetzt man diesen "*" mit der Klasse des eben betrachteten Beispiels. Wenn der Baum bei einem Beispiel die passende Klasse ausgibt, macht man mit dem nächsten Beispiel weiter. Wenn der Baum bei einem Beispiel eine andere Klasse ausgibt, muss das Klassensymbol im Baum (an der Stelle, wo das Objekt gelandet ist) durch den nächsten Test ersetzt werden: Hierzu nimmt man das nächste, auf diesem konkreten Pfad noch nicht verwendete Merkmal. CAL2 kann nur mit diskreten Attributen und disjunkten Klassen einen fehlerfreien Baum erzeugen.

Videos

- VL CAL2

1 Entscheidungsbäume: Klassifikation

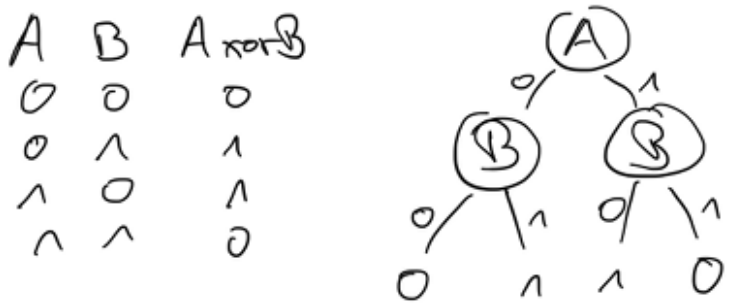

- Attribute als Knoten im Baum
- Ausprägungen als Test (Ausgang, Verzweigung)
- Klasse (Funktionswert) als Blatt

Erinnern Sie sich an das Beispiel mit der Auto-Reparatur aus der letzten Sitzung.

Die relevanten Eigenschaften (Merkmale) eines Autos würden als Knoten im Baum repräsentiert. Beispiel: "Motor startet" oder "Farbe".

Jedes Merkmal hat eine Anzahl von möglichen Ausprägungen, diese entsprechen den Verzweigungen am Knoten. Beispiel: "startet", "startet nicht" oder "rot", "weiß", "silber", … .

Entsprechend kann man durch Abarbeiten des Entscheidungsbaumes am Ende zu einer Diagnose gelangen (Klasse).

Eine andere Sichtweise ist die Nutzung als Checkliste für eine Reparatur …

2 Definition Entscheidungsbaum

- Erinnerung: **Merkmalsvektor** für Objekt v:

$$\mathbf{x}(v) = (x_1, x_2, \ldots, x_n)$$

  - n Merkmale (Attribute)
  - Attribut x_t hat m_t mögliche Ausprägungen
  - Ausprägung von v bzgl. x_t: $\quad x_t(v) = i \quad$ (mit $i = 1 \ldots m_t$)

- **Alphabet** für Baum:

$$\{x_t | t = 1, \ldots, n\} \cup \{\kappa | \kappa = *, A, B, C, \ldots\} \cup \{(,)\}$$

- **Entscheidungsbaum** α:

$$\alpha = \begin{cases} \kappa & \text{Terminalsymbole: } \kappa = *, A, B, \ldots \\ x_t(\alpha_1, \alpha_2, \ldots, \alpha_{m_t}) & x_t \text{ Testattribut mit } m_t \text{ Ausprägungen} \end{cases}$$

Anmerkung: Stellen Sie sich die linearisierte Schreibweise wieder wie den (verschachtelten) Aufruf von Konstruktoren vor. Es gibt die Oberklasse `Baum`, von der für jedes Attribut eine Klasse abgeleitet wird. D.h. der Konstruktor für eine Attributklasse erzeugt letztlich ein Objekt vom Obertyp `Baum`. Außerdem sind die Terminalsymbole `A`, `B`, … Objekte vom Typ `Blatt`, welches eine Unterklasse von `Baum` ist …

Dabei wird die Anzahl der möglichen Ausprägungen für ein Attribut berücksichtigt: Jede Ausprägung hat einen Parameter im Konstruktor. Damit werden die Unterbäume beim Erzeugen des Knotens übergeben.

3 Induktion von Entscheidungsbäumen: CAL2

1) Anfangsschritt: $\alpha^{(0)} = *$ (totales Unwissen)

2) n-ter Lernschritt: Objekt v mit Klasse k, Baum $\alpha^{(n-1)}$ gibt κ aus

   - $\kappa = *$: ersetze $*$ durch k
   - $\kappa = k$: keine Aktion nötig
   - $\kappa \neq k$: Fehler
     - Ersetze κ mit neuem Test: $\kappa \leftarrow x_{t+1}(*, \ldots, *, k, *, \ldots, *)$
     - x_{t+1}: nächstes Attribut, auf dem aktuellen Pfad noch nicht verwendet
     - Symbol k an Position i wenn $x_{t+1}(v) = i$

$\alpha^{(n)}$ bezeichnet den Baum im n-ten Lernschritt.

CAL2 ist ein **Meta-Algorithmus**: Es ist ein Algorithmus, um einen Algorithmus zu lernen :-)

4 Beispiel mit CAL2

x_1	x_2	x_3	k
0	0	1	A
1	0	0	A
0	1	4	B
1	1	2	B
0	0	3	A

Ergebnis: $x_1(x_2(A, B), x_2(A, B))$

Anmerkung: Denken Sie an die Analogie von oben. x_1 kann als Konstruktor einer Klasse `x1` betrachtet werden, die eine Unterklasse von `Baum` ist. Durch den Aufruf des Konstruktors wird als ein `Baum` erzeugt.

Es gibt in x_1 zwei mögliche Ausprägungen, d.h. der Baum hat in diesem Knoten zwei alternative Ausgänge. Diese Unterbäume werden dem Konstruktor von `x1` direkt beim Aufruf übergeben (müssen also Referenzen vom Typ `Baum` sein).

5 CAL2: Bemerkungen

- Nur für diskrete Merkmale und disjunkte Klassen

- Zyklischer Durchlauf durch Trainingsmenge
- Abbruch:
  - Alle Trainingsobjekte richtig klassifiziert
    => Kein Fehler in einem kompletten Durchlauf
  - (Differenzierung nötig, aber alle Merkmale verbraucht)
  - (Lernschrittzahl überschritten)

6 Wrap-Up

- Darstellung der Hypothese als Entscheidungsbaum
- CAL2: diskrete Attribute, disjunkte Klassen

7 Zum Nachlesen

- Unger und Wysotzki (1981): Der Vollständigkeit halber aufgeführt (Werk ist leider vergriffen und wird nicht mehr verlegt)

Lernziele

- k3: Ich kann den Entscheidungsbaumlerner CAL2 auf ein Beispiel anwenden

Quizzes

- Selbsttest CAL2 (ILIAS)

Challenges

Modellierung

Sie stehen vor der Entscheidung, ob Sie sich zur Vorbereitung auf die Flipped-Classroom-Sitzung noch das Skript anschauen.

Zeichnen Sie einen Entscheidungsbaum, der Ihnen bei der Entscheidung hilft.

Textklassifikation

Betrachten Sie die folgenden Aussagen:

> - Patient A hat weder Husten noch Fieber und ist gesund.
> - Patient B hat Husten, aber kein Fieber und ist gesund.
> - Patient C hat keinen Husten, aber Fieber. Er ist krank.
> - Patient D hat Husten und kein Fieber und ist krank.
> - Patient E hat Husten und Fieber. Er ist krank.

Aufgaben:

1. Trainieren Sie auf diesem Datensatz einen Klassifikator mit CAL2.
2. Ist Patient F krank? Er hat Husten, aber kein Fieber.

Handsimulation CAL2

Zeigen Sie mit einer Handsimulation, wie CAL2 mit dem folgenden Trainingsdatensatz schrittweise einen Entscheidungsbaum generiert. Nutzen Sie die linearisierte Schreibweise.

Beispiel	x_1	x_2	x_3	Klasse
1	a	a	a	1
2	a	b	a	2
3	a	a	b	1
4	b	a	b	1
5	a	a	c	1
6	b	b	b	2

Welchen Entscheidungsbaum würde CAL2 lernen, wenn dem Trainingsdatensatz der Vektor $((a, a, b), 2)$ als Beispiel Nr. 7 hinzugefügt werden würde?

Quellen

Unger, S., und F. Wysotzki. 1981. *Lernfähige Klassifizierungssysteme (Classifier Systems Which Are Able to Learn)*. Berlin: Akademie-Verlag.

Unless otherwise noted, this work is licensed under CC BY-SA 4.0.

> **Last modified:** d12a1c1 (lecture: add DTL to title (DTL), 2025-08-29)