

DTL: Entropie

Carsten Gips (HSBI)

Unless otherwise noted, this work is licensed under CC BY-SA 4.0.

Wie Attribute wählen?

Relevanz → Informationsgehalt

- Shannon/Weaver (1949): **Entropie**
 - Maß für die Unsicherheit einer Zufallsvariablen
 - Anzahl der Bits zur Darstellung der Ergebnisse eines Zufallsexperiments

Beispiele

- Münze, die immer auf dem Rand landet: keine Unsicherheit, 0 Bit
- Faire Münze: Kopf oder Zahl: Entropie 1 Bit
- Fairer 4-seitiger Würfel: 4 mögliche Ausgänge: Entropie 2 Bit
- Münze, die zu 99% auf einer Seite landet: Entropie nahe Null


→ Anzahl der Ja/Nein-Fragen, um zur gleichen Information zu kommen

Definition der Entropie $H(V)$ für Zufallsvariable V

- Zufallsvariable $V \rightarrow$ mögliche Werte v_k
- Wahrscheinlichkeit für v_k sei $p_k = P(v_k)$

$$H(V) = - \sum_k p_k \log_2 p_k$$

Hinweis: $\log_2 x = \frac{\log_{10} x}{\log_{10} 2} = \frac{\log x}{\log 2}$



Beispiele Entropie: faire Münze

Entropie:

$$H(V) = - \sum_k p_k \log_2 p_k$$

- $v_1 = \text{Kopf}, v_2 = \text{Zahl}$
- $p_1 = 0.5, p_2 = 0.5$
- $H(\text{Fair}) = -(0.5 \log_2 0.5 + 0.5 \log_2 0.5) = 1 \text{ Bit}$

$$\log_2 0.5 = -1$$

Beispiele Entropie: unfaire Münze

Entropie:

$$H(V) = - \sum_k p_k \log_2 p_k$$

Beispiele Entropie: unfaire Münze

Entropie:

$$H(V) = - \sum_k p_k \log_2 p_k$$

- $v_1 = \text{Kopf}, v_2 = \text{Zahl}$
- $p_1 = 0.99, p_2 = 0.01$
- $H(\text{UnFair}) = -(0.99 \log_2 0.99 + 0.01 \log_2 0.01)$
 $H(\text{UnFair}) \approx 0.08 \text{ Bit}$

$$\log_2 0.01 \approx -6.64$$

$$\log_2 0.99 \approx -0,014$$

Beispiele Entropie: 4-seitiger Würfel

Entropie:

$$H(V) = - \sum_k p_k \log_2 p_k$$

Beispiele Entropie: 4-seitiger Würfel

Entropie:

$$H(V) = - \sum_k p_k \log_2 p_k$$

- $v_1 = 1, v_2 = 2, v_3 = 3, v_4 = 4$
- $p_1 = p_2 = p_3 = p_4 = 0.25$
- $H(\text{Wuerfel}) = -4 \cdot (0.25 \log_2 0.25) = 2 \text{ Bit}$

$$\log_2 0.25 = -2$$

Entropie der Trainingsmenge: Häufigkeit der Klassen zählen

Nr.	x_1	x_2	x_3	k
1	0	0	0	A
2	1	0	2	A
3	0	1	1	A
4	1	1	0	B
5	0	1	1	B
6	0	1	0	A

- Anzahl Klasse A: 4
- Anzahl Klasse B: 2
- Gesamtzahl Beispiele: 6

Wahrscheinlichkeit für A: $p_A = 4/6 = 0.667$

Wahrscheinlichkeit für B: $p_B = 2/6 = 0.333$

Entropie der Trainingsmenge: Häufigkeit der Klassen zählen

Nr.	x_1	x_2	x_3	k
1	0	0	0	A
2	1	0	2	A
3	0	1	1	A
4	1	1	0	B
5	0	1	1	B
6	0	1	0	A

- Anzahl Klasse A: 4
- Anzahl Klasse B: 2
- Gesamtzahl Beispiele: 6

Wahrscheinlichkeit für A: $p_A = 4/6 = 0.667$

Wahrscheinlichkeit für B: $p_B = 2/6 = 0.333$

$$H(S) = - \sum_k p_k \log_2 p_k \quad (1)$$

$$= -(4/6 \cdot \log_2 4/6 + 2/6 \cdot \log_2 2/6) \quad (2)$$

$$= -(-0.39 - 0.53) = 0.92 \text{ Bit} \quad (3)$$

Mittlere Entropie nach Betrachtung von Attribut A

$$R(S, A) = \sum_{v \in \text{Values}(A)} \frac{|S_v|}{|S|} H(S_v)$$

Entropie der Trainingsmenge nach Attributwahl

Nr.	x_1	x_2	x_3	k
1	0	0	0	A
2	1	0	2	A
3	0	1	1	A
4	1	1	0	B
5	0	1	1	B
6	0	1	0	A

- Sei Attribut x_1 ausgewählt
- x_1 partitioniert die Trainingsmenge
 - $x_1 = 0$ liefert $S_0 = \{1, 3, 5, 6\}$
 - $x_1 = 1$ liefert $S_1 = \{2, 4\}$
 - Häufigkeit für $x_1 = 0$: $4/6$
 - Häufigkeit für $x_1 = 1$: $2/6$
 - Gesamtzahl Beispiele: 6

Entropie der Trainingsmenge nach Attributwahl

Nr.	x_1	x_2	x_3	k
1	0	0	0	A
2	1	0	2	A
3	0	1	1	A
4	1	1	0	B
5	0	1	1	B
6	0	1	0	A

- Sei Attribut x_1 ausgewählt
- x_1 partitioniert die Trainingsmenge
 - $x_1 = 0$ liefert $S_0 = \{1, 3, 5, 6\}$
 - $x_1 = 1$ liefert $S_1 = \{2, 4\}$
 - Häufigkeit für $x_1 = 0$: 4/6
 - Häufigkeit für $x_1 = 1$: 2/6
 - Gesamtzahl Beispiele: 6

$$R(S, A) = \sum_{v \in \text{Values}(A)} \frac{|S_v|}{|S|} H(S_v) \quad (4)$$

$$= 4/6 \cdot H(\{1, 3, 5, 6\}) + 2/6 \cdot H(\{2, 4\}) \quad (5)$$

$$= 4/6 \cdot (-3/4 \cdot \log_2 3/4 - 1/4 \cdot \log_2 1/4) + \quad (6)$$

$$2/6 \cdot (-1/2 \cdot \log_2 1/2 - 1/2 \cdot \log_2 1/2) \quad (7)$$

$$= 0.54 + 0.33 = 0.87 \text{ Bit} \quad (8)$$

- Begriff und Berechnung der Entropie: Maß für die Unsicherheit
- Begriff und Berechnung des Informationsgewinns
 - Entropie für eine Trainingsmenge
 - Mittlere Entropie nach Wahl eines Attributs



Unless otherwise noted, this work is licensed under CC BY-SA 4.0.

