DTL6: ID3 und C4.5

Carsten Gips (HSBI)

Unless otherwise noted, this work is licensed under CC BY-SA 4.0.

Wie Attribute wählen?

Erinnerung: CAL2

- Zyklische Iteration durch die Trainingsmenge
- Ausschließlich aktuelles Objekt betrachtet
- Reihenfolge der “richtigen” Attributwahl bei Verzweigung unklar

$\rightarrow$ Betrachte stattdessen die **komplette** Trainingsmenge!

Erinnerung Entropie: Maß für die Unsicherheit

- Entropie $H(S)$ der Trainingsmenge S: Häufigkeit der Klassen zählen
- Mittlere Entropie nach Betrachtung von Attribut A

$$R(S, A) = \sum_{v \in \text{Values}(A)} \frac{|S_v|}{|S|} H(S_v)$$

- Informationsgewinn durch Betrachtung von Attribut A

$$\begin{aligned} \text{Gain}(S, A) &= H(S) - R(S, A) && (1) \\ &= H(S) - \sum_{v \in \text{Values}(A)} \frac{|S_v|}{|S|} H(S_v) && (2) \end{aligned}$$

$\rightarrow$ Je kleiner $R(S, A)$, um so größer der Informationsgewinn

Informationsgewinn: Kriterium zur Auswahl von Attributen

1) Informationsgewinn für alle Attribute berechnen
2) Nehme Attribut mit größtem Informationsgewinn als nächsten Test

Nr.	x_1	x_2	x_3	k
1	0	0	0	A
2	1	0	2	A
3	0	1	1	A
4	1	1	0	B
5	0	1	1	B
6	0	1	0	A

$H(S) = 0.92\,\text{Bit}$

$$
\begin{aligned}
\text{Gain}(S, x_1) &= 0.92 - 0.87 = 0.05\,\text{Bit} && (3)\\
\text{Gain}(S, x_2) &= 0.92 - 2/6 \cdot 0 - 4/6 \cdot 1 && (4)\\
&= 0.25\,\text{Bit} && (5)\\
\text{Gain}(S, x_3) &= 0.92 - 3/6 \cdot 0.92 - 2/6 \cdot 1 - 1/6 \cdot 0 && (6)\\
&= 0.13\,\text{Bit} && (7)
\end{aligned}
$$

Informationsgewinn für x_2 am höchsten $\rightarrow$ wähle x_2 als nächsten Test

Entscheidungsbaumlerner ID3 (Quinlan, 1986)

```
def ID3(examples, attr, default):
    # Abbruchbedingungen
    if examples.isEmpty():  return default
    if examples.each(class == A):  return A  # all examples have same class
    if attr.isEmpty():  return examples.MajorityValue()

    # Baum mit neuem Test erweitern
    test = MaxInformationGain(examples, attr)
    tree = new DecisionTree(test)
    m = examples.MajorityValue()
    for v_i in test:
        ex_i = examples.select(test == v_i)
        st = ID3(ex_i, attr - test, m)
        tree.addBranch(label=v_i, subtree=st)
    return tree
```

Tafelbeispiel Anfang ID3

Beobachtung: Gain ist bei mehrwertigen Attributen höher

- Faire Münze:
  - Entropie $= H(\text{Fair}) = -(0.5 \log_2 0.5 + 0.5 \log_2 0.5) = 1\,\text{Bit}$
- 4-seitiger Würfel:
  - Entropie $= H(\text{Dice}) = -4 \cdot (0.25 \log_2 0.25) = 2\,\text{Bit}$

$\rightarrow$ Gain ist bei mehrwertigen Attributen höher

C4.5 als Verbesserung zu ID3

Normierter Informationsgewinn: $\text{Gain}(S, A) \cdot \text{Normalisation}(A)$

$$\text{Normalisation}(A) = \frac{1}{\sum_{v \in \text{Values}(A)} p_v \log_2 \frac{1}{p_v}}$$

Beispiele zur Normierung bei C4.5

- Faire Münze:
  - Entropie $= H(\text{Fair}) = -(0.5 \log_2 0.5 + 0.5 \log_2 0.5) = 1\,\text{Bit}$
  - Normierung: $1/(0.5 \log_2(1/0.5) + 0.5 \log_2(1/0.5)) = 1/(0.5 \cdot 1 + 0.5 \cdot 1) = 1$
  - Normierter Informationsgewinn: $\text{Gain}(S, A) \cdot \text{Normalisation}(A) = 1\,\text{Bit} \cdot 1 = 1\,\text{Bit}$
- 4-seitiger Würfel:
  - Entropie $= H(\text{Dice}) = -4 \cdot (0.25 \log_2 0.25) = 2\,\text{Bit}$
  - Normierung: $1/(4 \cdot 0.25 \log_2(1/0.25)) = 1/(4 \cdot 0.25 \cdot 2) = 0.5$
  - Normierter Informationsgewinn: $\text{Gain}(S, A) \cdot \text{Normalisation}(A) = 2\,\text{Bit} \cdot 0.5 = 1\,\text{Bit}$

$\rightarrow$ Normierung sorgt für fairen Vergleich der Attribute

Wrap-Up

- Entscheidungsbaumlerner **ID3**
  - Nutze *Information Gain* zur Auswahl des nächsten Attributs
  - Teile die Trainingsmenge entsprechend auf (“nach unten hin”)
- Verbesserung durch Normierung des *Information Gain*: **C4.5**



Unless otherwise noted, this work is licensed under CC BY-SA 4.0.

Last modified: *2411636 2026-10-12 markdown: reformat text*