DTL: ID3 und C4.5

Carsten Gips (HSBI)

TL;DR
Der Entscheidungsbaum-Lernalgorithmus **ID3** nutzt den Informationsgehalt für die Entscheidung bei der Attributwahl: Nimm das Attribut, welches einen möglichst hohen Informationsgehalt hat. Oder andersherum: Wähle das Attribut, bei dem die verbleibende mittlere Entropie der Trainingsmenge nach der Wahl des Attributs am kleinsten ist. Oder noch anders formuliert: Nimm das Attribut, bei dem die Differenz zwischen der Entropie der Trainingsmenge (vor der Wahl des Attributs) und der verbleibenden mittleren Entropie (nach der Wahl des Attributs) am größten ist (die Differenz nennt man auch "*Information Gain*"). Die Trainingsmenge wird entsprechend der Ausprägung in Bezug auf das eben gewählte Merkmal aufgeteilt und an die Kinder des Knotens weiter gereicht; dort wird der Baum rekursiv weiter aufgebaut.
Durch eine Normierung des *Information Gain* kann eine Verbesserung in Bezug auf mehrwertige Attribute erreicht werden, dies führt zum Algorithmus **C4.5**.

Videos

- VL ID3 und C4.5

1 Wie Attribute wählen?

Erinnerung: CAL2/CAL3

- Zyklische Iteration durch die Trainingsmenge
- Ausschließlich aktuelles Objekt betrachtet
- Reihenfolge der "richtigen" Attributwahl bei Verzweigung unklar

=> Betrachte stattdessen die **komplette** Trainingsmenge!

2 Erinnerung Entropie: Maß für die Unsicherheit

- Entropie $H(S)$ der Trainingsmenge S: relative Häufigkeit der Klassen zählen
- Mittlere Entropie nach Betrachtung von Attribut A

$$R(S, A) = \sum_{v \in \text{Values}(A)} \frac{|S_v|}{|S|} H(S_v)$$

- Informationsgewinn durch Betrachtung von Attribut A

$$\begin{aligned} \text{Gain}(S, A) &= H(S) - R(S, A) && (1) \\ &= H(S) - \sum_{v \in \text{Values}(A)} \frac{|S_v|}{|S|} H(S_v) && (2) \end{aligned}$$

$R(S, A)$ ist die Unsicherheit/nötige Bits nach Auswahl von Attribut A. Je kleiner $R(S, A)$, um so kleiner die **verbleibende Unsicherheit** bzw. um so kleiner die Anzahl der nötigen Bits zur Darstellung der partitionierten Trainingsmenge **nach** Betrachtung von Attribut A ...

=> Je kleiner $R(S, A)$, um so größer der Informationsgewinn

3 Informationsgewinn: Kriterium zur Auswahl von Attributen

1) Informationsgewinn für alle Attribute berechnen
2) Nehme Attribut mit größtem Informationsgewinn als nächsten Test

Nr.	x_1	x_2	x_3	k
1	0	0	0	A
2	1	0	2	A
3	0	1	1	A
4	1	1	0	B
5	0	1	1	B
6	0	1	0	A

$H(S) = 0.92$ Bit

$$\begin{aligned}
\text{Gain}(S, x_1) &= 0.92 - 0.87 = 0.05 \text{ Bit} && (3)\\
\text{Gain}(S, x_2) &= 0.92 - 2/6 \cdot 0 - 4/6 \cdot 1 && (4)\\
&= 0.25 \text{ Bit} && (5)\\
\text{Gain}(S, x_3) &= 0.92 - 3/6 \cdot 0.92 - 2/6 \cdot 1 - 1/6 \cdot 0 && (6)\\
&= 0.13 \text{ Bit} && (7)
\end{aligned}$$

Informationsgewinn für x_2 am höchsten => wähle x_2 als nächsten Test

4 Entscheidungsbaumlerner ID3 (Quinlan, 1986)

```
def ID3(examples, attr, default):
    # Abbruchbedingungen
    if examples.isEmpty():  return default
```

```
    if examples.each(class == A):  return A  # all examples have same class
    if attr.isEmpty():  return examples.MajorityValue()

    # Baum mit neuem Test erweitern
    test = MaxInformationGain(examples, attr)
    tree = new DecisionTree(test)
    m = examples.MajorityValue()
    for v_i in test:
        ex_i = examples.select(test == v_i)
        st = ID3(ex_i, attr - test, m)
        tree.addBranch(label=v_i, subtree=st)
    return tree
```

Russell und Norvig (2021): Man erhält aus dem "Learn-Decision-Tree"-Algorithmus (Russell und Norvig 2021, 678, Fig. 19.5) den hier vorgestellten ID3-Algorithmus, wenn man die Funktion Importance$(a, examples)$ als InformationGain$(examples, attr)$ implementiert/nutzt.

Hinweis: Mit der Zeile `if examples.each(class == A): return A` soll ausgedrückt werden, dass alle ankommenden Trainingsbeispiele die selbe Klasse haben und dass diese dann als Ergebnis zurückgeliefert wird. Das "A" steht im obigen Algorithmus nur symbolisch für die selbe Klasse! Es kann also auch ein anderes Klassensymbol als "A" sein …

4.1 Beispiel ID3

Nr.	x_1	x_2	x_3	k
1	0	0	0	A
2	1	0	2	A
3	0	1	1	A
4	1	1	0	B
5	0	1	1	B
6	0	1	0	A

- $x2$ höchsten Information Gain
- $x2 = 0$ => Beispiele 1,2 => A
- $x2 = 1$ => Beispiele 3,4,5,6 => Information Gain berechnen, weiter teilen und verzweigen

5 Beobachtung: Gain ist bei mehrwertigen Attributen höher

- Faire Münze:
  - Entropie = $H(\text{Fair}) = -(0.5 \log_2 0.5 + 0.5 \log_2 0.5) = 1$ Bit
- 4-seitiger Würfel:

- Entropie = $H(\text{Dice}) = -4 \cdot (0.25 \log_2 0.25) = 2$ Bit

=> Gain ist bei mehrwertigen Attributen höher

Damit würden Attribute bei der Wahl bevorzugt, nur weil sie mehr Ausprägungen haben als andere.

Anmerkung: Im obigen Beispiel wurde einfach die Entropie für zwei "Attribute" mit unterschiedlich vielen Ausprägungen betrachtet, das ist natürlich kein Gain(S, A). Aber es sollte deutlich machen, dass Merkmale mit mehr Ausprägungen bei der Berechnung des Gain für eine Trainingsmenge einfach wegen der größeren Anzahl an Ausprägungen rechnerisch bevorzugt würden.

6 C4.5 als Verbesserung zu ID3

Normierter Informationsgewinn: Gain$(S, A) \cdot$ Normalisation(A)

$$\text{Normalisation}(A) = \frac{1}{\sum_{v \in \text{Values}(A)} p_v \log_2 \frac{1}{p_v}}$$

C4.5 kann zusätzlich u.a. auch noch mit kontinuierlichen Attributen umgehen, vgl. en.wikipedia.org/wiki/C4.5_algorithm.

In einem Paper (DOI 10.1007/s10115-007-0114-2) wurde der Algorithmus zu den "Top 10 algorithms in data mining" ausgewählt.

Im Wikipedia-Artikel Information Gain finden Sie weitere Informationen zum "Informationsgewinn" (*Information Gain*).

Ein anderer, relativ ähnlich arbeitender Entscheidungsbaumlerner ist der CART (Classification And Regression Tree)-Algorithmus, wobei der Begriff "CART" allerdings oft auch einfach allgemein für "Entscheidungsbaumlerner" genutzt wird.

Hierzu drei lesenswerte Blog-Einträge:

- Deep dive into the basics of Gini Impurity in Decision Trees with math Intuition
- Decision Trees, Explained
- Decision Tree Algorithm With Hands-On Example

7 Beispiele zur Normierung bei C4.5

- Faire Münze:
  - Entropie = $H(\text{Fair}) = -(0.5 \log_2 0.5 + 0.5 \log_2 0.5) = 1$ Bit
  - Normierung: $1/(0.5 \log_2(1/0.5) + 0.5 \log_2(1/0.5)) = 1/(0.5 \cdot 1 + 0.5 \cdot 1) = 1$
  - Normierter Informationsgewinn: Gain$(S, A) \cdot$ Normalisation$(A) = 1$ Bit $\cdot 1 = 1$ Bit

- 4-seitiger Würfel:

  - Entropie = $H(\text{Dice}) = -4 \cdot (0.25 \log_2 0.25) = 2$ Bit
  - Normierung: $1/(4 \cdot 0.25 \log_2(1/0.25)) = 1/(4 \cdot 0.25 \cdot 2) = 0.5$
  - Normierter Informationsgewinn: Gain$(S, A) \cdot$ Normalisation$(A) = 2$ Bit $\cdot 0.5 = 1$ Bit

=> Normierung sorgt für fairen Vergleich der Attribute

Anmerkung: Auch hier ist die Entropie natürlich kein Gain(S, A). Das Beispiel soll nur übersichtlich deutlich machen, dass der "Vorteil" von Attributen mit mehr Ausprägungen durch die Normierung in C4.5 aufgehoben wird.

8 Wrap-Up

- Entscheidungsbaumlerner **ID3**
  - Nutze *Information Gain* zur Auswahl des nächsten Attributs
  - Teile die Trainingsmenge entsprechend auf ("nach unten hin")
- Verbesserung durch Normierung des *Information Gain*: **C4.5**

9 Zum Nachlesen

- Ertel (2025): Entscheidungsbäume: Abschnitt 8.4
- Russell und Norvig (2021): Entscheidungsbäume: Abschnitt 19.3
- Mitchell (2010): ID3: Kapitel 3

Lernziele

- k3: Ich kann die Entscheidungsbaumalgorithmen ID3 und C4.5 auf konkrete Daten anwenden.

Challenges

Textklassifikation

Betrachten Sie die folgenden Aussagen:

> - Patient A hat weder Husten noch Fieber und ist gesund.
> - Patient B hat Husten, aber kein Fieber und ist gesund.
> - Patient C hat keinen Husten, aber Fieber. Er ist krank.
> - Patient D hat Husten und kein Fieber und ist krank.
> - Patient E hat Husten und Fieber. Er ist krank.

Aufgaben:

1. Trainieren Sie auf diesem Datensatz einen Klassifikator mit ID3.
2. Ist Patient F krank? Er hat Husten, aber kein Fieber.

Quellen

Ertel, W. 2025. *Grundkurs Künstliche Intelligenz*. 6th edition. Springer Vieweg Wiesbaden. https://doi.org/10.1007/978-3-658-44955-1.

Mitchell, T. 2010. *Machine Learning*. McGraw-Hill.

Russell, S., und P. Norvig. 2021. *Artificial Intelligence: A Modern Approach*. 4th Edition. Pearson. http://aima.cs.berkeley.edu.

Unless otherwise noted, this work is licensed under CC BY-SA 4.0.

> **Last modified:** 10f17df (lecture: update to 2025 edition of Ertel, 2025-09-27)