DTL7: Random Forest

Carsten Gips (HSBI)

Unless otherwise noted, this work is licensed under CC BY-SA 4.0.

Vom einzelnen Baum zum Wald

- Idee:
  - Statt **einem** Baum viele **verschiedene** Bäume trainieren
  - Jeder Baum trifft eine eigene Vorhersage
  - Am Ende: **Mehrheitsentscheidung** bzw. **Mittelwert**

- Intuition:
  - "Viele verschiedene Meinungen" kombinieren $\rightarrow$ robustere Entscheidung
  - Fehler einzelner Bäume können sich gegenseitig ausgleichen

Wie funktioniert ein Random Forest?

1. **Datenbasis**: Trainingsdatensatz D

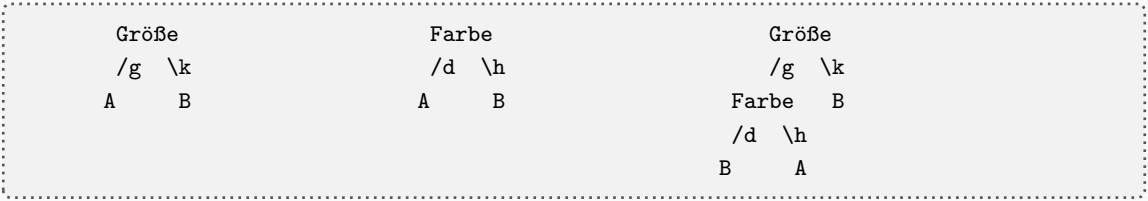
2. **Viele (Teil-) Trainingsdatensätze durch Zufall (Bootstrapping/Bagging)**
   - Für jeden Baum $B_1, B_2, \ldots, B_k$:
     - Zufälliges Ziehen (mit Zurücklegen) der Trainingsbeispiele aus D
       $\rightarrow$ jeder Baum erhält eine leicht andere Stichprobe D_k

3. **Zufällige Merkmalsauswahl pro Split (Feature-Subsampling)**
   - Beim Training eines Baums:
     - an jedem Knoten nur zufällige Teilmenge der Attribute für den Split betrachten
     - daraus das "beste" Attribut wählen (Entropie)
   - Alternativ: Anzahl der Splits begrenzen

4. **Vorhersage**
   - Klassifikation: Mehrheitsentscheid der Vorhersagen der Bäume
   - Regression: Mittelwert der Vorhersagen der Bäume

Beispiel: Random Forest in Aktion (Klassifikation)

Bäume:



Testobjekt: (Größe = groß, Farbe = hell)

Vorhersage:



Mehrheitsentscheidung: 2x A, 1x B $\rightarrow$ **A**

Pseudocode: Random Forest

Training:

```
Input: Trainingsdaten D, Anzahl Bäume K,
       Anzahl Zufallsattribute pro Split m

For k = 1 .. K:
    Ziehe Zufallsstichprobe D_k aus D (mit Zurücklegen)   // bagging
    Trainiere Entscheidungsbaum T_k auf D_k:
        An jedem Knoten:
            Wähle zufällig m Attribute aus allen Attributen
            Finde unter diesen m Attributen den besten Split (Entropie)
Output: Ensemble {T_1, T_2, ..., T_K}
```

Vorhersage für ein neues Objekt x:

- Klassifikation: $\hat{y}_{\text{class}}(x) = \text{argmax}_{c \in C} \sum_{k=1}^{K} \mathbf{1}\big[T_k(x) = c\big]$
- Regression: $\hat{y}_{\text{reg}}(x) = \frac{1}{K} \sum_{k=1}^{K} T_k(x)$

Wrap-Up

- **Random Forest**:
  - Kombiniert viele (kleine) Entscheidungsbäume
  - Training auf zufälligen Teilmengen der Daten und Merkmalen (Bagging + Feature-Subsampling)
- Gesamtvorhersage: **Mehrheitsvotum** der Bäume bzw. Mittelwertbildung
- Ensemble **reduziert Varianz**
- Wichtige Hyperparameter:
  - Anzahl der Bäume
  - Anzahl der Merkmale pro Split
  - Maximale Baumtiefe



Unless otherwise noted, this work is licensed under CC BY-SA 4.0.

Last modified: *2411636 2026-10-12 markdown: reformat text*