Wiederholung Wahrscheinlichkeitstheorie

Carsten Gips (HSBI)

TL;DR
Diese Sitzung ist eine (relativ oberflächliche) Einführung/Wiederholung in die/der Grundlagen der Wahrscheinlichkeitstheorie.
Wir schauen uns die möglichen Ausgänge eines Zufallsexperiments an ("Ereignisse"). Wenn diese Ereignisse sich gegenseitig ausschließen und alle denkbaren Ergebnisse abdecken, dann nennt man diese Ereignisse auch **Elementarereignisse**. Die Wahrscheinlichkeit für ein Ereignis kann man angeben als Anzahl der möglichen Ergebnisse, die für dieses Ereignis günstig sind, geteilt durch die Anzahl aller Ausgänge. Über die Kolmogorov Axiome bekommt man die typischen Rechenregel für die Wahrscheinlichkeit.
Man kann eine **Verbundwahrscheinlichkeit** $P(A, B) = P(B, A)$ angeben, das ist die Wahrscheinlichkeit, dass A und B gleichzeitig auftreten.
Die **bedingte** Wahrscheinlichkeit für A gegeben B ist $P(A|B)$ und berechnet sich $P(A|B) = \frac{P(A,B)}{P(B)}$.
Daraus kann man die **Bayes-Regel** ableiten:

$$P(A|B) = \frac{P(B|A)P(A)}{P(B)}$$

Dabei nennt man

- $P(A)$ **"Prior"** oder **"A-priori-Wahrscheinlichkeit"** (die Wahrscheinlichkeit für A ohne weiteres Wissen),
- $P(B|A)$ **"Likelihood"** (Wie wahrscheinlich ist das Auftreten von B, gegeben A?),
- $P(A|B)$ **"Posterior"** oder **"A-posteriori-Wahrscheinlichkeit"** (Wie wahrscheinlich ist A, wenn B eingetreten ist?), und
- $P(B)$ ist ein Normierungsfaktor (Wie wahrscheinlich ist B an sich?).

Videos

- VL Wahrscheinlichkeiten

---

1 Ereignisse und Wahrscheinlichkeit

Hinweis: Die folgende Darstellung zur Einführung in die Wahrscheinlichkeitstheorie dient dem Verständnis des Naive Bayes Klassifikationsalgorithmus und ist teilweise eher oberflächlich gehalten. Sie kann und soll keine entsprechende mathematische Einführung ersetzen!

1.1 Ereignisse

- **Ereignisse** $\Omega = \{\omega_1, \omega_2, \ldots, \omega_n\}$: endliche Menge der Ausgänge eines Zufallsexperiments
- **Elementarereignis**: Die $\omega_i \in \Omega$
  - decken *alle* möglichen Versuchsergebnisse ab, und
  - schließen sich gegenseitig aus

1.2 Regeln

- Wenn A und B Ereignisse sind, dann auch $A \cup B$
- Ω wird als **sicheres Ereignis** bezeichnet: Enthält definitionsgemäß **alle** Versuchsausgänge, d.h. *ein* in der Menge enthaltenes Ereignis *muss* auftreten
- Die leere Menge $\emptyset$ wird als **unmögliches Ereignis** bezeichnet
- Die Variablen A und B heißen auch **Zufallsvariablen**

Im Rahmen dieser Veranstaltung betrachten wir nur diskrete Zufallsvariablen mit endlichem Wertebereich!

1.3 Wahrscheinlichkeit

- **Wahrscheinlichkeit**:

  Sei $\Omega = \{\omega_1, \omega_2, \ldots, \omega_n\}$ endlich. Die Wahrscheinlichkeit $P(A)$ für ein Ereignis A ist dann definiert als

  $$P(A) = \frac{|A|}{|\Omega|} = \frac{\text{Anzahl der für A günstigen Fälle}}{\text{Anzahl der möglichen Fälle}}$$

  Man könnte auch schreiben: $P(A) = \sum_{\omega \in A} P(\omega)$

  Hinweis: Diese Definition von Wahrscheinlichkeit geht von gleich wahrscheinlichen Elementarereignissen aus! Die allgemeine Definition geht über einen entsprechenden Grenzwert.

1.4 Verteilung

Den Vektor mit den Wahrscheinlichkeiten aller Elementarereignisse nennt man auch *Verteilung*.

Beispiel: $\mathbf{P}(A) = (P(A = 1), P(A = 2), \ldots, P(A = 6)) = (1/6, 1/6, \ldots, 1/6)$

Hinweis: Wir betrachten hier nur diskrete Zufallsvariablen. Für kontinuierliche Variablen wird die Verteilung mit Hilfe einer **Dichtefunktion** dargestellt, beispielsweise der Gauss'schen Funktion.

1.5 Beispiel

- Einmaliges Würfeln mit einem Spielwürfel: $\Omega = \{1, 2, 3, 4, 5, 6\}$
- Elementarereignisse: $\{1, 2, 3, 4, 5, 6\}$
- Das Würfeln einer geraden Zahl ($A = \{2, 4, 6\}$) ist *kein* Elementarereignis, ebenso wie das Würfeln einer Zahl kleiner 5 ($B = \{1, 2, 3, 4\}$), da $A \cap B = \{2, 4\} \neq \emptyset$
- Wahrscheinlichkeit, eine 1 zu würfeln: $P(A \in \{1\}) = P(A = 1) = \frac{1}{6}$. *Anmerkung*: Man schreibt statt $P(A \in \{1\})$ oft einfach $P(1)$.
- Wahrscheinlichkeit, eine gerade Zahl zu würfeln: $P(A \in \{2, 4, 6\}) = P(A = 2 \vee A = 4 \vee A = 6) = \frac{|\{2,4,6\}|}{|\{1,2,3,4,5,6\}|} = \frac{3}{6} = 0.5$

2 Rechenregeln: Kolmogorov Axiome

Sei A ein Ereignis, also $A \subseteq \Omega$:

- $0 \leq P(A) \leq 1$
- $\Omega = \{\omega_1, \omega_2, \ldots, \omega_n\}$: $\sum_i P(\omega_i) = 1$ (Normierungsbedingung: Summe über die Wahrscheinlichkeiten aller Elementarereignisse ist immer 1)
- $P(A \cup B) = P(A) + P(B) - P(A \cap B)$

Daraus folgt (u.a.):

- $P(\Omega) = 1$
- $P(\emptyset) = 0$
- $P(A) = 1 - P(\neg A)$

- A und B *unabhängig*: $P(A \cup B) = P(A) + P(B)$
- $P(A \cap B)$ ist leer, wenn A und B sich nicht überlappen
- $A \subseteq B$: $P(A) \leq P(B)$

3 Verbundwahrscheinlichkeiten

$$P(A, B) = P(B, A) = \text{ Wahrscheinlichkeit, dass A und B gleichzeitig auftreten}$$

	Halsschmerzen	¬ Halsschmerzen
Schnupfen	0.04	0.06
¬ Schnupfen	0.01	0.89

- $P(S, H) = 0.04$

Die Tabelle kann man so lesen: In 4 von 100 Fällen tritt das Ereignis “Schnupfen” gleichzeitig mit dem Ereignis “Halsschmerzen” auf, in 6 von 100 Fällen tritt “Schupfen” ohne Halsschmerzen auf. … In Summe kommt man wieder auf 100 Fälle (100 Prozent).

Nach diesen Zahlen liegt also die Verbundwahrscheinlichkeit für die Ereignisse “Schnupfen” und “Husten”, d.h. $P(S, H)$, bei 4 Prozent.

Hinweis: Die gezeigten Zahlen und Zusammenhänge sind **fiktiv** und dienen lediglich zur Verdeutlichung der Wahrscheinlichkeitsbegriffe!

4 Bedingte Wahrscheinlichkeit

Definition: Bedingte Wahrscheinlichkeit für A gegeben B:

$$P(A|B) = \frac{P(A,B)}{P(B)}$$

	Halsschmerzen	¬ Halsschmerzen
Schnupfen	0.04	0.06
¬ Schnupfen	0.01	0.89

- $P(\text{Schnupfen} \mid \text{Halsschmerzen}) = \frac{P(S,H)}{P(H)} = \frac{0.04}{0.04+0.01} = 0.8$
- $P(\text{Halsschmerzen} \mid \text{Schnupfen}) = \frac{P(H,S)}{P(S)} = \frac{0.04}{0.04+0.06} = 0.4$

Wegen $P(A|B) = \dfrac{P(A,B)}{P(B)}$ ist $P(A,B) = P(A|B)P(B) = P(B|A)P(A)$ (**Produkt-Regel**)!

5 Marginalisierung

	Halsschmerzen	¬ Halsschmerzen	$\sum$
Schnupfen	0.04	0.06	*0.1*
¬ Schnupfen	0.01	0.89	*0.9*
$\sum$	*0.05*	*0.95*	*1*

$P(S) = P(S,H) + P(S,\neg H)$

Allgemein: Seien $B_1, \ldots, B_n$ Elementarereignisse mit $\bigcup_i B_i = \Omega$. Dann ist

$$P(A) = \sum_i P(A, B_i) = \sum_i P(A|B_i)P(B_i)$$

Diesen Vorgang nennt man **Marginalisierung**. Die resultierende Verteilung $P(A)$ nennt man auch *"Randverteilung"*, da sie mit einer Projektion eines Quaders auf eine Seitenfläche vergleichbar ist.

6 Kettenregel

- **Produktregel**: Wegen $P(A|B) = \frac{P(A,B)}{P(B)}$ gilt $P(A,B) = P(A|B)P(B)$

- Verallgemeinerung (**Kettenregel**):

$$\begin{aligned}
P(A_1, A_2, \ldots, A_n) &= P(A_n, \ldots, A_2, A_1) \\
&= P(A_n|A_{n-1}, \ldots, A_1)P(A_{n-1}, \ldots, A_1) \\
&= P(A_n|A_{n-1}, \ldots, A_1)P(A_{n-1}|A_{n-2}, \ldots, A_1)P(A_{n-2}, \ldots, A_1) \\
&= \ldots \\
&= P(A_n|A_{n-1}, \ldots, A_1) \ldots P(A_2|A_1)P(A_1) \\
&= \textstyle\prod_i P(A_i|A_1, \ldots, A_{i-1})
\end{aligned}$$

7 Bayes-Regel

Bedingte Wahrscheinlichkeit: $P(A,B) = P(A|B)P(B) = P(B|A)P(A)$

$$P(A|B) = \frac{P(B|A)P(A)}{P(B)}$$

- $P(A)$ nennt man **"Prior"** oder **"A-priori-Wahrscheinlichkeit"** (Das ist die Wahrscheinlichkeit für A ohne weiteres Wissen)
- $P(B|A)$ nennt man **"Likelihood"** (Wie wahrscheinlich ist das Auftreten von B, gegeben A?)
- $P(A|B)$ nennt man **"Posterior"** oder **"A-posteriori-Wahrscheinlichkeit"** (Wie wahrscheinlich ist A, wenn B eingetreten ist?)
- $P(B)$ ist ein Normierungsfaktor

Wenn man (siehe später: Naive Bayes Klassifikator) A als Klasse und B als Daten betrachtet:

- $P(A)$: Wie wahrscheinlich ist eine bestimmte Klasse an sich (A-priori-Wahrscheinlichkeit der Klassen)?
- $P(B|A)$: Wie wahrscheinlich sind bestimmte Daten, gegeben die Klasse A? (Likelihood der Daten)
- $P(A|B)$: Gegeben die Daten B, wie wahrscheinlich ist die Klasse A? (Posterior)

In der Medizin hat sucht man i.d.R. die Ursache für beobachtete Symptome:

$$P(\text{Ursache}|\text{Symptome}) = \frac{P(\text{Symptome}|\text{Ursache})P(\text{Ursache})}{P(\text{Symptome})}$$

Aus der A-priori-Wahrscheinlichkeit für bestimmte Krankheiten und der Likelihood der Symptome (wie wahrscheinlich sind Symptome, gegeben eine Krankheit) kann man die Wahrscheinlichkeit für das Vorliegen einer Erkrankung gegeben bestimmte Symptome berechnen.

8 Beispiel Bayes

- Bei Arthrose wird in 80 Prozent der Fälle ein steifes Gelenk beobachtet
- Eine von 10.000 Personen hat Arthrose
- Eine von 10 Personen hat ein steifes Gelenk

=> Ich habe ein steifes Gelenk. Habe ich Arthrose?

- Gegeben: $P(A) = 0.0001, P(S) = 0.1, P(S|A) = 0.8$
- Gesucht: $P(A|S)$

$$P(A|S) = \frac{P(S|A)P(A)}{P(S)} = \frac{0.8 \times 0.0001}{0.1} = 0.0008 = 0.08\%$$

Wenn ein steifes Gelenk vorliegt, ist die Wahrscheinlichkeit, dann an Arthrose erkrankt zu sein, bei nur 0.08%. Kein Grund zur Sorge in diesem Fall :-)

=> Wie wahrscheinlich ist ein steifes Gelenk ohne Arthrose, also $P(S|\neg A)$?

Mit Marginalisierung: $P(S) = P(S|A)P(A) + P(S|\neg A)P(\neg A)$,
d.h. $0.1 = 0.8 \times 0.0001 + P(S|\neg A) \times (1 - 0.0001)$, d.h. $P(S|\neg A) = 0.0999$

In knapp 10 Prozent der Fälle würde man im obigen Beispiel bei der Diagnose “keine Arthrose” ein steifes Gelenk beobachten.

Hinweis: Die genannten Zahlen und Zusammenhänge sind rein fiktional und sollen lediglich zur Veranschaulichung der Bayes-Regel dienen!

Schauen Sie sich auch das Beispiel 7.9 in (Ertel 2017, Ex. 7.9, S. 135) an!

9 Unabhängige Ereignisse

- $P(\text{Halsschmerzen, Regen}) = P(\text{Regen} \mid \text{Halsschmerzen})P(\text{Halsschmerzen})$
- $P(\text{Regen} \mid \text{Halsschmerzen}) = \text{??} = P(\text{Regen})$

- Zwei Ereignisse A und B sind **unabhängig**, wenn

$$P(A|B) = P(A)$$

=> $P(A, B) = P(A|B)P(B) = P(A)P(B)$

Dies kann man verallgemeinern (**bedingte Unabhängigkeit**):

> X und Y sind *bedingt unabhängig* (gegeben Z), wenn $P(X|Y, Z) = P(X|Z)$ bzw. $P(Y|X, Z) = P(Y|Z)$

Daraus folgt:

$$P(X, Y|Z) = P(X|Y, Z)P(Y|Z) = P(X|Z)P(Y|Z)$$

10 Wrap-Up

- Grundlagen der Wahrscheinlichkeitstheorie
  - Elementarereignisse und Wahrscheinlichkeit
  - Rechenregeln
  - Bedingte Wahrscheinlichkeit und Verbundwahrscheinlichkeit
  - Marginalisierung
  - (Bedingte) Unabhängigkeit
  - Bayes'sche Regel

11 Zum Nachlesen

- Russell und Norvig (2020): Kapitel 12
- Ertel (2017): Abschnitt 7.1

Lernziele

- k2: Elementarereignisse und Wahrscheinlichkeit
- k2: Bedingte Wahrscheinlichkeit und Verbundwahrscheinlichkeit
- k2: (Bedingte) Unabhängigkeit
- k3: Rechenregeln
- k3: Marginalisierung
- k3: Bayes'sche Regel

Quizzes

- Selbsttest Wahrscheinlichkeiten (ILIAS)

Quellen

Ertel, W. 2017. *Introduction to Artificial Intelligence*. 2nd edition. Springer. https://doi.org/10.1007/978-3-319-58487-4.

Russell, S., und P. Norvig. 2020. *Artificial Intelligence: A Modern Approach*. 4th Edition. Pearson. http://aima.cs.berkeley.edu.

Unless otherwise noted, this work is licensed under CC BY-SA 4.0.

> **Last modified:** 2fdb622 (lecture: fix minor formatting issues, 2025-07-17)