NB: Klassifikation mit Naive Bayes

Carsten Gips (HSBI)

TL;DR
Mit Hilfe der (verallgemeinerten) Bayes-Regel kann man Klassifikation durchführen. Dazu werden beim "Training" die bedingten Wahrscheinlichkeiten aus den Trainingsdaten geschätzt. Die Anwendung (Klassifikation) erfolgt dann durch die Nutzung der beim "Training" berechneten bedingten Wahrscheinlichkeiten:
$h_{MAP} = \text{argmax}_{h \in H}\ P(h|D_1, \ldots, D_n) = \text{argmax}_{h \in H}\ P(h) \prod_i P(D_i|h)$
Für jede Hypothese h, d.h. für jede Klasse, wird der Posterior $P(h|D_1, \ldots, D_n)$ ausgerechnet. Die Klasse, deren Wert dabei am höchsten ist, "gewinnt", d.h. die Klasse mit dem größten Posterior wird ausgegeben. (Deshalb wird das Verfahren oft auch "MAP" – *Maximum a Posteriori* – genannt.)
Bei der Berechnung wird angenommen, dass die betrachteten Merkmale (bedingt) unabhängig sind (dies geht in die obige Formel ein). Diese Annahme trifft aber oft nicht zu, deshalb auch der Name "*Naive* Bayes Klassifikation". Man berechnet in diesem Fall falsche Werte. Dennoch zeigt der Algorithmus in der Praxis sehr gute Ergebnisse.
Durch den Einsatz der bedingten Wahrscheinlichkeiten in der Produktformel ergeben sich einige Schwierigkeiten:

1. Wenn beim "Training" Ausprägungen fehlen, ist die bedingte Wahrscheinlichkeit Null. Dadurch wird das gesamte Produkt Null. Zur Abhilfe kann man den **Laplace-Schätzer** nutzen, der (gesteuert über einen Parameter) gewissermaßen virtuelle Trainingsbeispiele beisteuert.
2. Durch das Produkt vieler kleiner Werte kann es schnell zu *Floating Point*-Underflows kommen. Hier kann man einen Trick nutzen: Man berechnet den Logarithmus der Produktformel. Dadurch ändern sich zwar die absoluten Werte, die Reihenfolge der Hypothesen bleibt aber erhalten. Da wir nur nach der Hypothese suchen, die einen höheren Wert als die anderen hat, und nicht den absoluten Wert an sich benötigen, kann man so vorgehen. Durch den Logarithmus wird aus dem Produkt eine Summe, wo die kleinen Werte der bedingten Wahrscheinlichkeiten nicht so starke Auswirkungen haben wie im Produkt.

Oft nimmt man zusätzlich an, dass für alle Hypothesen (Klassen) h der Prior $P(h)$ gleich ist. Dann kann man diesen Faktor ebenfalls aus der Berechnung entfernen. Dieses Verfahren nennt man auch "**Maximum Likelihood**".
Der NB-Klassifikator wird gern für die Textklassifikation eingesetzt. Hier muss man einem Text ein Label zuordnen. In einer Vorverarbeitung wird zunächst eine Menge der relevanten Wörter über alle Trainingstexte gebildet (*Bag-of-Words*). Der Bag-of-Words entspricht einem Merkmalsvektor, wobei die Merkmale die einzelnen Wörter sind. Dann kann jeder Text der Trainingsmenge über so einen Merkmalsvektor dargestellt werden: Entweder man gibt pro Merkmal an, ob es da (1) oder nicht da (0) ist oder man zählt die Häufigkeit des Auftretens. Dann kann man mit dem NB-Klassifikator die bedingten Wahrscheinlichkeiten schätzen und einen neuen Text klassifizieren.

Videos

- VL Naive Bayes Klassifikation

1 Medizinische Diagnostik mit NB

- Bei Arthrose wird in 80 Prozent der Fälle ein steifes Gelenk beobachtet: $P(S|A) = 0.8$
- Eine von 10.000 Personen hat Arthrose: $P(A) = 0.0001$
- Eine von 10 Personen hat ein steifes Gelenk: $P(S) = 0.1$

=> Ich habe ein steifes Gelenk. Habe ich Arthrose?

2 Textklassifikation mit NB

- Mails, manuell markiert:
  - D1: (“Sieben Zwerge fraßen sieben Ziegen”, OK)
  - D2: (“Sieben Ziegen traten sieben Wölfe”, SPAM)
  - D3: (“Sieben Wölfe fraßen sieben Böcke”, OK)
  - D4: (“Sieben Böcke traten sieben Zwerge”, SPAM)

- Neue Mails:
  - T1: (“Sieben Zwerge fraßen sieben Wölfe”)
  - T2: (“Sieben Zwerge traten sieben Ziegen”)

Lernen Sie mit Hilfe der Trainingsmenge einen Naive-Bayes-Klassifikator und wenden Sie diesen auf die beiden Test-Dokumente an.

3 Naive Bayes

- Verallgemeinerte Bayes Regel

$$P(H|D_1,\ldots,D_n) = \frac{P(D_1,\ldots,D_n|H)P(H)}{P(D_1,\ldots,D_n)}$$

- Annahme: D_i sind bedingt unabhängig

$$P(D_1,\ldots,D_n|H) = P(D_1|H)\cdot\ldots\cdot P(D_n|H) = \prod_i P(D_i|H)$$

- Beobachtung: $P(D_1,\ldots,D_n)$ für alle Hypothesen $h \in H$ gleich

- **Naive Bayes Klassifikator** bzw. **MAP** (“Maximum a Posteriori”)

$$h_{MAP} = \underset{h\in H}{\text{argmax}}\ P(h|D_1,\ldots,D_n) = \underset{h\in H}{\text{argmax}}\ P(h)\prod_i P(D_i|h)$$

  Naive Bayes: Wähle die plausibelste Hypothese, die von den Daten unterstützt wird.

4 Bayes’sches Lernen

$$h_{MAP} = \underset{h\in H}{\text{argmax}}\ P(h|D_1,\ldots,D_n) = \underset{h\in H}{\text{argmax}}\ P(h)\prod_i P(D_i|h)$$

Training: Bestimme die Wahrscheinlichkeiten aus Trainingsdaten $\mathbf{S}$

- Für jede Klasse h:
  - Schätze $P(h) = \frac{|S(h)|}{|S|}$
  - Für jedes Attribut D_i und jede Ausprägung $x \in D_i$:
    Schätze $P(D_i = x|h) = \frac{|S_{D_i}(x) \cap S(h)|}{|S(h)|}$

Klassifikation: Wähle wahrscheinlichste Klasse h_{MAP} für Vektor $\mathbf{x}$

- $h_{MAP} = \text{argmax}_{h \in H} \; P(h) \prod_{x \in \mathbf{x}} P(x|h)$

5 Beispiel Klassifikation mit NB

Nase läuft	Husten	Gerötete Haut	Fieber	Klasse
1	1	1	0	krank
1	1	0	0	krank
0	0	1	1	krank
1	0	0	0	gesund
0	0	0	0	gesund

- Eingabe: Person mit Husten und Fieber

Gesucht: $P(\text{krank})$, $P(\text{gesund})$, $P(\text{Nase=0}|\text{krank})$, $P(\text{Nase=0}|\text{gesund})$, ...

Wähle Klasse

$$h_{MAP} = \underset{h \in \{\text{gesund, krank}\}}{\text{argmax}} \quad P(h) \cdot P(\text{Nase=0}|h) \cdot P(\text{Husten=1}|h) \tag{1}$$

$$\cdot P(\text{Haut=0}|h) \cdot P(\text{Fieber=1}|h) \tag{2}$$

Ergebnis: (nur die für den zu klassifizierenden Beispiel-Vektor nötigen Werte, die restlichen müssten aber auch beim "Training" berechnet werden!)

```
P(gesund) = 2/5 = 0.4
P(krank)  = 3/5 = 0.6

P(Nase=0 | gesund) = 1/2 = 0.5
P(Nase=0 | krank)  = 1/3 = 0.333

P(Husten=1 | gesund) = 0/2 = 0
P(Husten=1 | krank)  = 2/3 = 0.667

P(Haut=0 | gesund) = 2/2 = 1
```

```
P(Haut=0 | krank)  = 1/3 = 0.333

P(Fieber=1 | gesund) = 0/2 = 0
P(Fieber=1 | krank)  = 1/3 = 0.333

h = gesund: P(gesund) * P(Nase=0 | gesund) * P(Husten=1 | gesund) * P(Haut=0 |
    gesund) * P(Fieber=1 | gesund) = 0.4*0.5*0*1*0              = 0
h = krank:  P(krank)  * P(Nase=0 | krank)  * P(Husten=1 | krank)  * P(Haut=0 |
    krank)  * P(Fieber=1 | krank)  = 0.6*0.333*0.667*0.33*0.333 = 0.015
```

=> Klasse “krank” gewinnt (Wert für $P(\text{krank})$ ist der höchste der beiden Hypothesen) …

6 Textklassifikation mit NB

- Texte als Trainingsmenge:
  - Text zerlegen in Terme (Wörter, sonstige relevante Token)
  - ggf. Entfernen von Stoppwörtern (beispielsweise Artikel u.ä.)
  - ggf. Stemming und Lemmatisierung für restliche Terme
  - ggf. weitere Vorverarbeitungsschritte (Groß-Klein-Schreibung, …)
  - Terme zusammenfassen als Menge: *“Bag of Words”* (mit Häufigkeit)

- Naive Bayes “trainieren”:
  - A-priori-Wahrscheinlichkeit der Klassen: $P(c) = \frac{N_c}{N} = \frac{\text{Anzahl Dokumente in Klasse c}}{\text{Anzahl Dokumente}}$
  - Likelihood der Daten (Terme):
    * $P(t|c) = \frac{\text{count}(t,c)}{\sum_{v \in V} \text{count}(v,c)}$
      mit $\text{count}(t,c)$ Anzahl der Vorkommen von Term t in allen Dokumenten der Klasse c und V die Vereinigung aller Terme aller Dokumente (als Menge)
    * Variante mit Laplace-Glättung (s.u.): $P(t|c) = \frac{\text{count}(t,c)+1}{\sum_{v \in V} \text{count}(v,c) + |V|}$

7 Naivität im Naive Bayes

- Unabhängigkeit der Attribute oft nicht gegeben

  => $P(D_1, \ldots, D_n|H) \neq \prod_i P(D_i|H)$
- A-posteriori-Wahrscheinlichkeiten oft unrealistisch nah an 1 oder 0

- Praxis: Dennoch häufig sehr gute Ergebnisse

  Wichtig: Solange die **Maximierung** über alle Hypothesen die selben Ergebnisse liefert, müssen die konkreten Schätzungen/Werte nicht exakt stimmen …

Wenn Attribute nicht (bedingt) unabhängig sind, kann sich der NB verschätzen, d.h. es kommt dann u.U. zu einer höheren Fehlerrate, da bestimmte Eigenschaften in der Trainingsmenge zu hoch gewichtet werden.

7.1 Beispiel

7.1.1 Gegebene Daten

Seien die beiden Merkmale x_1 und x_2 mit den folgenden Verteilungen gegeben:

- Klassen: $H \in \{0, 1\}$, $P(H = 0) = P(H = 1) = 0.5$
- Bedingte Verteilungen $P(x_1, x_2|H)$:
  - Für $H = 0$:
    * $P(x_1 = 0, x_2 = 0|0) = 0.30$
    * $P(x_1 = 0, x_2 = 1|0) = 0.35$
    * $P(x_1 = 1, x_2 = 0|0) = 0.15$
    * $P(x_1 = 1, x_2 = 1|0) = 0.20$
  - Für $H = 1$:
    * $P(x_1 = 0, x_2 = 0|1) = 0.00$
    * $P(x_1 = 0, x_2 = 1|1) = 0.30$
    * $P(x_1 = 1, x_2 = 0|1) = 0.65$
    * $P(x_1 = 1, x_2 = 1|1) = 0.05$

7.1.2 Analyse der gegebenen Daten

Die Merkmale x_1 und x_2 sind *nicht* bedingt abhängig gegeben H.
Erinnerung: Zwei Ereignisse X und Y sind bedingt unabhängig gegeben Z, wenn gilt $P(X, Y|Z) = P(X|Y, Z)P(Y|Z) = P(X|Z)P(Y|Z)$.
Wir haben aber im Fall von $H = 1$:

- $P(x_1 = 0, x_2 = 0|1) = 0.00$ vs. $P(x_1 = 0|1)P(x_2 = 0|1) = (0.00 + 0.30) * (0.00 + 0.65) = 0.30 * 0.65 = 0.195$
- $P(x_1 = 0, x_2 = 1|1) = 0.30$ vs. $P(x_1 = 0|1)P(x_2 = 1|1) = (0.00 + 0.30) * (0.30 + 0.05) = 0.30 * 0.35 = 0.105$
- $P(x_1 = 1, x_2 = 0|1) = 0.65$ vs. $P(x_1 = 1|1)P(x_2 = 0|1) = (0.65 + 0.05) * (0.00 + 0.65) = 0.70 * 0.65 = 0.455$
- $P(x_1 = 1, x_2 = 1|1) = 0.05$ vs. $P(x_1 = 1|1)P(x_2 = 1|1) = (0.65 + 0.05) * (0.30 + 0.05) = 0.70 * 0.35 = 0.245$

(analog für $H = 0$)
Damit bekommen wir im Naive Bayes Klassifikator ein Problem. Dort wird von bedingt unabhängigen Merkmalen ausgegangen und deshalb die Vereinfachung von $P(x_1, x_2|H)$ zu $P(x_1|H)P(x_2|H)$ vorgenommen. Da die Annahme nicht stimmt, werden die Merkmale falsch gewichtet und es kann zu Fehlklassifikationen kommen.

7.1.3 Klassifikation einer Beobachtung

Wir machen nun die folgende Beobachtung: $X = (x_1 = 1, x_2 = 1)$.
Die nötigen Marginalisierungen aus den Trainingsdaten für diese Beobachtung sind:

- Für $H = 0$: $P(x_1 = 1|0) = 0.15 + 0.20 = 0.35$, $P(x_2 = 1|0) = 0.35 + 0.20 = 0.55$
- Für $H = 1$: $P(x_1 = 1|1) = 0.65 + 0.05 = 0.70$, $P(x_2 = 1|1) = 0.30 + 0.05 = 0.35$

Anwendung der Naive Bayes Klassifikation (mit Annahme bedingt unabhängige Merkmale): Wir nutzen $h_{MAP} = \text{argmax}_{h \in H}\ P(h|D_1, \ldots, D_n) = \text{argmax}_{h \in H}\ P(h) \prod_i P(D_i|h)$ und setzen unsere beiden Merkmale ein: $h_{MAP} = \text{argmax}_{h \in H}\ P(h|x_1, x_2) = \text{argmax}_{h \in H}\ P(h)P(x_1|h)P(x_2|h)$.
Damit bekommen wir folgende Entscheidung:

8 Laplace-Schätzer

- Problem: Attribut-Ausprägung für bestimmte Klasse nicht in Trainingsmenge:
  - => Bedingte Wahrscheinlichkeit ist 0
  - => Produkt gleich 0

- Lösung: "Laplace-Schätzer" (auch "Laplace-Glättung")

  Statt $P(D_i = x|h) = \frac{|S_{D_i}(x) \cap S(h)|}{|S(h)|}$

  nutze $P(D_i = x|h) = \frac{|S_{D_i}(x) \cap S(h)| + m \cdot p_i}{|S(h)| + m}$

  - mit m: frei wählbarer Faktor, und
  - p_i: A-priori-Wahrscheinlichkeit für $P(D_i = x|h)$

    Hintergrundwissen oder einfach *uniforme Verteilung der Attributwerte*: $p_i = 1/|D_i|$ (Wahrscheinlichkeit für eine Attributausprägung ist 1/(Anzahl der Ausprägungen des Attributs))

  => "virtuelle" Trainingsbeispiele (m ist die Zahl der virtuellen Trainingsbeispiele)

9 Probleme mit Floating Point Underflow

- MAP berechnet Produkt mit vielen Termen
- Problem: Bei kleinen Zahlen kann **Floating Point Underflow** auftreten!

- Lösung: Logarithmus maximieren (Produkt geht in Summe über)

  Erinnerung: $\log(x \cdot y) = \log(x) + \log(y)$ und Logarithmus streng monoton

$$
\begin{aligned}
h_{MAP} &= \underset{h \in H}{\text{argmax}}\ P(h|D_1, \ldots, D_n) && (3)\\
&= \underset{h \in H}{\text{argmax}}\ P(h) \prod_i P(D_i|h) && (4)\\
&= \underset{h \in H}{\text{argmax}}\ [\log(P(h)) + \sum_i \log(P(D_i|h))] && (5)
\end{aligned}
$$

10 Maximum Likelihood

- **Maximum a Posteriori**

$$h_{MAP} = \underset{h \in H}{\text{argmax}}\ P(h|D_1, \ldots, D_n) = \underset{h \in H}{\text{argmax}}\ P(h) \prod_i P(D_i|h)$$

- Annahme: Klassen uniform verteilt => $P(h_i) = P(h_j)$

  Maximum Likelihood

  $$h_{ML} = \underset{h \in H}{\text{argmax}} \prod_i P(D_i|h)$$

  => Maximiere die Likelihood der Daten

11 Ausblick: Kontinuierliche Attribute

Bisher sind wir von diskreten Attributen ausgegangen. Bei kontinuierlichen Attributen hat man zwei Möglichkeiten:

- Diskretisierung der Attribute: Aufteilung in Intervalle und Bezeichnung der Intervalle mit einem Namen
- Einsatz einer Verteilungsannahme und deren Dichtefunktion, beispielsweise Annahme von **normalverteilten** Daten mit der Dichtefunktion

  $$f(x) = \frac{1}{\sqrt{2\pi\sigma}} e^{-\frac{(x-\mu)^2}{2\sigma^2}}$$

  wobei μ der Mittelwert und σ^2 die Varianz der Daten sind.

12 Hinweis zum Sprachgebrauch

In Abhängigkeit von der Verteilung der $P(D_i|h)$ spricht man von

- "multinominalem" NB: Attribute umfassen mehrere Kategorien (verschiedene Ausprägungen, wie im "Wahlkampf"-Beispiel: Attribut "Bildung" hat die Ausprägungen "Abitur", "Bachelor" und "Master")
- Bernoulli NB: Attribute sind binär (Ausprägung 0 oder 1), typischerweise bei der Textklassifikation
- Gauss'sches NB: Annahme einer Normalverteilung der Attribut-Ausprägungen

13 Wrap-Up

- Klassifikation mit Naive Bayes
  - Annahme von Unabhängigkeit => "Naive" Bayes Klassifikation
  - Schätzen der bedingten Wahrscheinlichkeiten aus den Trainingsdaten
  - Klassifikation durch Nutzung der geschätzten Wahrscheinlichkeiten
  - Hinweis auf Naivität der Annahme, dennoch sehr gute Erfolge in Praxis
  - Hinweis auf Probleme mit niedrigen Wahrscheinlichkeiten

14 Zum Nachlesen

Lesen Sie in (Russell und Norvig 2021) bitte den Abschnitt 12.6 “Naive Bayes Models”. Darüber hinaus ist Abschnitt “8.10 Der Naive Bayes Klassifikator” (Ertel 2025) sehr empfehlenswert.

Lernziele

- k2: Ich kann die Unabhängigkeits-Annahme in der ‘Naive’ Bayes Klassifikation erklären
- k2: Ich kann die Probleme mit niedrigen Wahrscheinlichkeiten erklären
- k3: Ich kann die bedingten Wahrscheinlichkeiten aus konkreten Trainingsdaten schätzen
- k3: Ich kann die Klassifikation mit Naive Bayes durch Nutzung der geschätzten Wahrscheinlichkeiten durchführen

Quizzes

- Selbsttest Naive Bayes Klassifikation (ILIAS)

Challenges

Spam-Mails

Stellen Sie sich vor, Sie haben eine Sammlung von 100 E-Mails (60 Spam, 40 Nicht-Spam). Sie wissen, dass das Wort “Gewinn” in 45 Spam-E-Mails und in 5 Nicht-Spam-E-Mails vorkommt.

1. Berechnen Sie die Wahrscheinlichkeit, dass es eine E-Mail Spam ist, wenn das Wort “Gewinn” darin vorkommt.
2. Wie würde die E-Mail mit dem Wort “Gewinn” durch einen Naive Bayes Klassifikator bewertet?

Textklassifikation

Betrachten Sie die folgenden Aussagen:

> - Patient A hat weder Husten noch Fieber und ist gesund.
> - Patient B hat Husten, aber kein Fieber und ist gesund.
> - Patient C hat keinen Husten, aber Fieber. Er ist krank.
> - Patient D hat Husten und kein Fieber und ist krank.
> - Patient E hat Husten und Fieber. Er ist krank.

Aufgaben:

1. Trainieren Sie auf diesem Datensatz einen Klassifikator mit NB.
2. Ist Patient F krank? Er hat Husten, aber kein Fieber.

Quellen

Ertel, W. 2025. *Grundkurs Künstliche Intelligenz*. 6th edition. Springer Vieweg Wiesbaden. https://doi.org/10.1007/978-3-658-44955-1.

Russell, S., und P. Norvig. 2021. *Artificial Intelligence: A Modern Approach*. 4th Edition. Pearson. http://aima.cs.berkeley.edu.

Unless otherwise noted, this work is licensed under CC BY-SA 4.0.

> **Last modified:** cac4843 (lecture: improve challenge (NB2), 2025-10-01)