NB: Text-Klassifikation mit Naive Bayes

Carsten Gips (HSBI)

Unless otherwise noted, this work is licensed under CC BY-SA 4.0.

Textklassifikation mit NB

- Trainingsdaten: Mails, manuell markiert:
  - D1: ("Die sieben Zwerge fraßen die sieben Ziegen", OK)
  - D2: ("Die sieben Ziegen traten die sieben Wölfe", SPAM)
  - D3: ("Die sieben Wölfe fraßen die sieben Böcke", OK)
  - D4: ("Die sieben Böcke traten die sieben Zwerge", OK)

- Testdaten (neue Mails):
  - T1: ("Die sieben Zwerge fraßen die sieben Wölfe")

Lernen Sie mit Hilfe der Trainingsmenge einen Naive-Bayes-Klassifikator und wenden Sie diesen auf die Test-Dokumente an.

Vorverarbeitung

- Vereinheitlichung: Kleinbuchstaben
- **Tokenisierung**: Aufteilung auf einzelne Wörter
- **Stop Words** entfernen: “der”, “die”, “das”, . . .
- **Lemmatisierung**: “fraßen” -> “fressen”, “Wölfe” -> “Wolf”, . . .
- **Synonyme, Homonyme, Akronyme** ersetzen
- **Stemming**
- **Terme**: Die erhaltenen Wörter nennen wir “Terme”.

Merkmalsvektor: Bag of Words

Nach Vorverarbeitung:

- Trainingsdaten (**Terme**):
  - D1: (sieben, zwerg, fressen, sieben, ziege; OK)
  - D2: (sieben, ziege, treten, sieben, wolf; SPAM)
  - D3: (sieben, wolf, fressen, sieben, bock; OK)
  - D4: (sieben, bock, treten, sieben, zwerg; OK)
- Testdaten (**Terme**):
  - T1: (sieben, zwerg, fressen, sieben, wolf)

Vokabular: V = {sieben, zwerg, fressen, ziege, treten, wolf, bock}

Bag of Words: Merkmalsvektor mit fester Anordnung des Vokabulars

Bag of Words für Trainingsdaten

- D1: (sieben, zwerg, fressen, sieben, ziege; OK)
- D2: (sieben, ziege, treten, sieben, wolf; SPAM)
- D3: (sieben, wolf, fressen, sieben, bock; OK)
- D4: (sieben, bock, treten, sieben, zwerg; OK)

	sieben	zwerg	fressen	ziege	treten	wolf	bock	Klasse
D1	2	1	1	1	0	0	0	OK
D2	2	0	0	1	1	1	0	SPAM
D3	2	0	1	0	0	1	1	OK
D4	2	1	0	0	1	0	1	OK

Naive Bayes Training (Multinomial NB)

	sieben	zwerg	fressen	ziege	treten	wolf	bock	Klasse
D1	2	1	1	1	0	0	0	OK
D2	2	0	0	1	1	1	0	SPAM
D3	2	0	1	0	0	1	1	OK
D4	2	1	0	0	1	0	1	OK

Klasse	sieben	zwerg	fressen	ziege	treten	wolf	bock	Anzahl Wörter	Anzahl Dokumente
OK	6	2	2	1	1	1	2	15	3
SPAM	2	0	0	1	1	1	0	5	1

Naive Bayes Training (Multinomial NB), cnt.

Klasse	sieben	zwerg	fressen	ziege	treten	wolf	bock	Anzahl Wörter	Anzahl Dokumente
OK	6	2	2	1	1	1	2	15	3
SPAM	2	0	0	1	1	1	0	5	1

Naive Bayes "trainieren"

- A-priori-Wahrscheinlichkeit der Klassen:
  $P(c) = \frac{N_c}{N} = \frac{\text{Anzahl Dokumente in Klasse c}}{\text{Anzahl Dokumente}}$
- Likelihood der Daten (Terme):
  $P(t|c) = \frac{\text{count}(t,c)}{\sum_{v \in V} \text{count}(v,c)}$
  mit $\text{count}(t,c)$ Anzahl der Vorkommen von Term t in allen Dokumenten der Klasse c und V die Vereinigung aller Terme aller Dokumente (Vokabular)

- A-priori-Wahrscheinlichkeit:
  - $P(\text{OK}) = 3/4 = 0.75$
  - $P(\text{SPAM}) = 1/4 = 0.25$
- Likelihood:
  - $P(\text{sieben}|\text{OK}) = (2+2+2)/(2+2+2+1+1+1+1+1+1+1+1+1) = 6/15 = 0.40$
  - $P(\text{sieben}|\text{SPAM}) = (2)/(2+1+1+1) = 2/5 = 0.40$
  - $P(\text{zwerg}|\text{OK}) = 2/15 = 0.133$
  - $P(\text{zwerg}|\text{SPAM}) = 0/5 = 0.00$
  - $P(\text{fressen}|\text{OK}) = 2/15 = 0.133$
  - $P(\text{fressen}|\text{SPAM}) = 0/5 = 0.00$
  - $P(\text{ziege}|\text{OK}) = 1/15 = 0.067$

Naive Bayes Klassifikation (Multinomial NB)

$h_{MAP} = \text{argmax}_{h \in H} \; P(h) \prod_{x \in \mathbf{x}} P(x|h)$

Naive Bayes Klassifikation (Multinomial NB)

$h_{MAP} = \text{argmax}_{h \in H} \; P(h) \prod_{x \in \mathbf{x}} P(x|h)$

Jedes Vorkommen eines Wortes im Testdatensatz ist ein x!

$$h_{MAP} = \underset{h \in H}{\text{argmax}} \; P(h) \prod_{w \in \mathbf{V}} P(w|h)^{\text{count}(\mathbf{w})}$$

T1: (sieben, zwerg, fressen, sieben, wolf)

- **H = OK**: $P(\text{OK}) \cdot P(\text{sieben}|\text{OK})^2 \cdot P(\text{zwerg}|\text{OK})^1 \cdot P(\text{fressen}|\text{OK})^1 \cdot P(\text{ziege}|\text{OK})^0 \cdot P(\text{treten}|\text{OK})^0 \cdot P(\text{wolf}|\text{OK})^1 \cdot P(\text{bock}|\text{OK})^0 = 0.75 * 0.40 * 0.40 * 0.133 * 0.133 * 1 * 1 * 0.067 * 1 = 0.00014221956$
- **H = SPAM**: $P(\text{SPAM}) \cdot P(\text{sieben}|\text{SPAM})^2 \cdot P(\text{zwerg}|\text{SPAM})^1 \cdot P(\text{fressen}|\text{SPAM})^1 \cdot P(\text{ziege}|\text{SPAM})^0 \cdot P(\text{treten}|\text{SPAM})^0 \cdot P(\text{wolf}|\text{SPAM})^1 \cdot P(\text{bock}|\text{SPAM})^0$
  $= 0.25 * 0.40 * 0.40 * 0.00 * 0.00 * 1 * 1 * 0.20 * 1 = 0.00$

Entscheidung: OK

Beobachtungen

Naive Bayes mit Laplace-Glättung (Multinomial NB)

$$P(t|c) = \frac{\text{count}(t,c) + \alpha}{\sum_{v \in V} \text{count}(v,c) + \alpha \cdot |V|}, \qquad \text{bei Laplace: } \alpha = 1$$

- A-priori-Wahrscheinlichkeit:
  - $P(\text{OK}) = 3/4 = 0.75$
  - $P(\text{SPAM}) = 1/4 = 0.25$
- Likelihood:
  - $P(\text{sieben}|\text{OK}) = (2+2+2+\mathbf{1})/(2+2+2+1+1+1+1+1+1+1+1+1+\mathbf{7}) = 7/22 = 0.318$ (vorher: 0.40)
  - $P(\text{sieben}|\text{SPAM}) = (2+\mathbf{1})/(2+1+1+1+\mathbf{7}) = 3/12 = 0.25$ (vorher: 0.40)
  - $P(\text{zwerg}|\text{OK}) = (2+\mathbf{1})/(15+\mathbf{7}) = 0.136$ (vorher: 0.133)
  - $P(\text{zwerg}|\text{SPAM}) = (0+\mathbf{1})/(5+\mathbf{7}) = 0.083$ (vorher: **0.00**)
  - $P(\text{fressen}|\text{OK}) = (2+\mathbf{1})/(15+\mathbf{7}) = 0.136$ (vorher: 0.133)
  - $P(\text{fressen}|\text{SPAM}) = (0+\mathbf{1})/(5+\mathbf{7}) = 0.083$ (vorher: **0.00**)
  - $P(\text{ziege}|\text{OK}) = (1+\mathbf{1})/(15+\mathbf{7}) = 0.091$ (vorher: 0.067)
  - $P(\text{ziege}|\text{SPAM}) = (1+\mathbf{1})/(5+\mathbf{7}) = 0.167$ (vorher: 0.20)
  - $P(\text{treten}|\text{OK}) = (1+\mathbf{1})/(15+\mathbf{7}) = 0.091$ (vorher: 0.067)
  - $P(\text{treten}|\text{SPAM}) = (1+\mathbf{1})/(5+\mathbf{7}) = 0.167$ (vorher: 0.20)
  - $P(\text{wolf}|\text{OK}) = (1+\mathbf{1})/(15+\mathbf{7}) = 0.091$ (vorher: 0.067)

Naive Bayes mit Laplace-Glättung (Multinomial NB), cnt.

T1: (sieben, zwerg, fressen, sieben, wolf)

- **H = OK**: $P(\text{OK}) \cdot P(\text{sieben}|\text{OK})^2 \cdot P(\text{zwerg}|\text{OK})^1 \cdot P(\text{fressen}|\text{OK})^1 \cdot P(\text{ziege}|\text{OK})^0 \cdot P(\text{treten}|\text{OK})^0 \cdot P(\text{wolf}|\text{OK})^1 \cdot P(\text{bock}|\text{OK})^0$
  $= 0.75 * 0.318 * 0.318 * 0.136 * 0.136 * 1 * 1 * 0.091 * 1 = 0.0001276540836$ (vorher: 0.00014221956)
- **H = SPAM**: $P(\text{SPAM}) \cdot P(\text{sieben}|\text{SPAM})^2 \cdot P(\text{zwerg}|\text{SPAM})^1 \cdot P(\text{fressen}|\text{SPAM})^1 \cdot P(\text{ziege}|\text{SPAM})^0 \cdot P(\text{treten}|\text{SPAM})^0 \cdot P(\text{wolf}|\text{SPAM})^1 \cdot P(\text{bock}|\text{SPAM})^0$
  $= 0.25 * 0.25 * 0.25 * 0.083 * 0.083 * 1 * 1 * 0.167 * 1 = 0,00001797598438$ (vorher: **0.00**)

Entscheidung: OK

Beobachtungen

Naive Bayes mit Out-of-Vocabulary-Termen (OOV, Multinomial NB)

T1: (sieben, zwerg, fressen, sieben, wolf, **lecker**)

- **H = OK**: $P(\text{OK}) \cdot P(\text{sieben}|\text{OK})^2 \cdot P(\text{zwerg}|\text{OK})^1 \cdot P(\text{fressen}|\text{OK})^1 \cdot P(\text{ziege}|\text{OK})^0 \cdot P(\text{treten}|\text{OK})^0 \cdot P(\text{wolf}|\text{OK})^1 \cdot P(\text{bock}|\text{OK})^0 \cdot \mathbf{P}(\text{lecker}|\text{OK})^{\mathbf{1}}$
- **H = SPAM**: $P(\text{SPAM}) \cdot P(\text{sieben}|\text{SPAM})^2 \cdot P(\text{zwerg}|\text{SPAM})^1 \cdot P(\text{fressen}|\text{SPAM})^1 \cdot P(\text{ziege}|\text{SPAM})^0 \cdot P(\text{treten}|\text{SPAM})^0 \cdot P(\text{wolf}|\text{SPAM})^1 \cdot P(\text{bock}|\text{SPAM})^0 \cdot \mathbf{P}(\text{lecker}|\text{SPAM})^{\mathbf{1}}$

$\mathbf{P}(\text{lecker}|\text{OK})$ und $\mathbf{P}(\text{lecker}|\text{SPAM})$ sind **unbekannt**!

Möglichkeiten:

1. Da im Training nicht vorgekommen: 0 als Wert für $P(\text{lecker}|c)$ annehmen
2. Term ignorieren
3. Ad-hoc Laplace einführen
4. Mit UNK-Term arbeiten im Training/Klassifikation

Naive Bayes mit UNK-Term (OOV, Multinomial NB)

Training

Klasse	sieben	zwerg	fressen	ziege	treten	wolf	bock	UNK	Anzahl Wörter	Anzahl Dokumente
OK	6	2	2	1	1	1	2	0	15	3
SPAM	2	0	0	1	1	1	0	0	5	1

- A-priori-Wahrscheinlichkeit:
  - $P(\text{OK}) = 3/4 = 0.75$
  - $P(\text{SPAM}) = 1/4 = 0.25$
- Likelihood:
  - $P(\text{sieben}|\text{OK}) = (2+2+2+1)/(2+2+2+1+1+1+1+1+1+1+1+1+\mathbf{8}) = 7/23 = 0.304$ (vorher: 0.318)
  - $P(\text{sieben}|\text{SPAM}) = (2+1)/(2+1+1+1+\mathbf{8}) = 3/13 = 0.231$ (vorher: 0.25)
  - ...
  - $P(\text{UNK}|\text{OK}) = (0+1)/(15+\mathbf{8}) = 0.043$
  - $P(\text{UNK}|\text{SPAM}) = (0+1)/(5+\mathbf{8}) = 0.077$

Naive Bayes mit UNK-Term (OOV, Multinomial NB), cnt.

Klassifikation

T1: (sieben, zwerg, fressen, sieben, wolf, **lecker**)

- **H = OK**: $P(\text{OK}) \cdot P(\text{sieben}|\text{OK})^2 \cdot P(\text{zwerg}|\text{OK})^1 \cdot P(\text{fressen}|\text{OK})^1 \cdot P(\text{ziege}|\text{OK})^0 \cdot P(\text{treten}|\text{OK})^0 \cdot P(\text{wolf}|\text{OK})^1 \cdot P(\text{bock}|\text{OK})^0 \cdot \mathbf{P}(\text{lecker}|\text{OK})^{\mathbf{1}}$
- **H = SPAM**: $P(\text{SPAM}) \cdot P(\text{sieben}|\text{SPAM})^2 \cdot P(\text{zwerg}|\text{SPAM})^1 \cdot P(\text{fressen}|\text{SPAM})^1 \cdot P(\text{ziege}|\text{SPAM})^0 \cdot P(\text{treten}|\text{SPAM})^0 \cdot P(\text{wolf}|\text{SPAM})^1 \cdot P(\text{bock}|\text{SPAM})^0 \cdot \mathbf{P}(\text{lecker}|\text{SPAM})^{\mathbf{1}}$

Mapping:

- $P(\text{lecker}|\text{OK}) => P(\text{UNK}|\text{OK}) = 0.043$
- $P(\text{lecker}|\text{SPAM}) => P(\text{UNK}|\text{SPAM}) = 0.077$

Naive Bayes Training (Bernoulli NB, mit Laplace)

	sieben	zwerg	fressen	ziege	treten	wolf	bock	Klasse
D1	1	1	1	1	0	0	0	OK
D2	1	0	0	1	1	1	0	SPAM
D3	1	0	1	0	0	1	1	OK
D4	1	1	0	0	1	0	1	OK

Klasse	sieben	zwerg	fressen	ziege	treten	wolf	bock	Anzahl Dokumente
OK	3	2	2	1	1	1	2	3
SPAM	1	0	0	1	1	1	0	1

Naive Bayes Training (Bernoulli NB, mit Laplace), cnt.

Klasse	sieben	zwerg	fressen	ziege	treten	wolf	bock	Anzahl Dokumente
OK	3	2	2	1	1	1	2	3
SPAM	1	0	0	1	1	1	0	1

Naive Bayes "trainieren"

- A-priori-Wahrscheinlichkeit der Klassen:
  $P(c) = \frac{N_c}{N} = \frac{\text{Anzahl Dokumente in Klasse c}}{\text{Anzahl Dokumente}}$
- Likelihood der Daten (Terme):
  - $P(t = 1|c) = \frac{\text{Anzahl Dokumente in Klasse c mit Term t} + \alpha}{\text{Anzahl Dokumente in Klasse c} + 2 \cdot \alpha}$
  - $P(t = 0|c) = 1 - P(t = 1|c)$

- A-priori-Wahrscheinlichkeit:
  - $P(\text{OK}) = 3/4 = 0.75$
  - $P(\text{SPAM}) = 1/4 = 0.25$
- Likelihood $\alpha = 1$:
  - $P(\text{sieben} = 1|\text{OK}) = (3 + 1)/(3 + 2) = 4/5 = 0.80$
  - $P(\text{sieben} = 1|\text{SPAM}) = (1 + 1)/(1 + 2) = 2/3 = 0.667$
  - $P(\text{zwerg} = 1|\text{OK}) = 3/5 = 0.60$
  - $P(\text{zwerg} = 1|\text{SPAM}) = 1/3 = 0.333$
  - $P(\text{fressen} = 1|\text{OK}) = 3/5 = 0.60$
  - $P(\text{fressen} = 1|\text{SPAM}) = 1/3 = 0.333$
  - $P(\text{ziege} = 1|\text{OK}) = 2/5 = 0.40$
  - $P(\text{ziege} = 1|\text{SPAM}) = 2/3 = 0.667$
  - $P(\text{treten} = 1|\text{OK}) = 2/5 = 0.40$

Naive Bayes Klassifikation (Bernoulli NB)

$h_{MAP} = \text{argmax}_{h \in H} \; P(h) \prod_{x \in \mathbf{x}} P(x|h)$

Naive Bayes Klassifikation (Bernoulli NB)

$h_{MAP} = \text{argmax}_{h \in H} \; P(h) \prod_{x \in \mathbf{x}} P(x|h)$

Für jedes Wort w im Vokabular V gibt es die Beobachtung (Bernoulli-Variable) $lw \in \{0, 1\}$.

$$h_{MAP} = \underset{h \in H}{\text{argmax}} \; P(h) \prod_{w \in \mathbf{V}} P(lw = 1|h)^{lw} \cdot (1 - P(lw = 1|h))^{1-lw}$$

T1: (sieben, zwerg, fressen, sieben, wolf)

- **H = OK**: $P(\text{OK}) \cdot P(\text{sieben} = 1|\text{OK}) \cdot P(\text{zwerg} = 1|\text{OK}) \cdot P(\text{fressen} = 1|\text{OK}) \cdot P(\text{ziege} = 0|\text{OK}) \cdot P(\text{treten} = 0|\text{OK}) \cdot P(\text{wolf} = 1|\text{OK}) \cdot P(\text{bock} = 0|\text{OK})$
  $= 0.75 * 0.80 * 0.60 * 0.60 * (1 - 0.40) * (1 - 0.40) * 0.40 * (1 - 0.60) = 0.0124416$
- **H = SPAM**: $P(\text{SPAM}) \cdot P(\text{sieben} = 1|\text{SPAM}) \cdot P(\text{zwerg} = 1|\text{SPAM}) \cdot P(\text{fressen} = 1|\text{SPAM}) \cdot P(\text{ziege} = 0|\text{SPAM}) \cdot P(\text{treten} = 0|\text{SPAM}) \cdot P(\text{wolf} = 1|\text{SPAM}) \cdot P(\text{bock} = 0|\text{SPAM})$
  $= 0.25 * 0.667 * 0.333 * 0.333 * (1 - 0.667) * (1 - 0.667) * 0.667 * (1 - 0.333) = 0.0009122091926$

Entscheidung: OK

Wrap-Up

- **Vorverarbeitung**: Tokenisierung, Vokabular, Bag of Words (BoW)
- **Multinomial NB**:
  - Zähle die Vorkommen eines Terms: $P(t|c) = \frac{\text{count}(t,c) + \alpha}{\sum_{v \in V} \text{count}(v,c) + \alpha \cdot |V|}$
  - Klassifikation mit $h_{MAP} = \text{argmax}_{h \in H} \; P(h) \prod_{w \in \mathbf{V}} P(w|h)^{\text{count}(w)}$
  - Im Test nicht vorhandene Terme t aus V werden ignoriert (Faktor 1)
- **Bernoulli NB**:
  - Prüfe das Vorkommen eines Terms: $P(t = 1|c) = \frac{\text{Anzahl Dokumente in Klasse c mit Term t} + \alpha}{\text{Anzahl Dokumente in Klasse c} + 2 \cdot \alpha}$
  - Klassifikation mit $h_{MAP} = \text{argmax}_{h \in H} \; P(h) \prod_{w \in \mathbf{V}} P(lw = 1|h)^{lw} \cdot (1 - P(lw = 1|h))^{1-lw}$
  - Im Test nicht vorhandene Terme t aus V werden korrekt mit $P(lw = 0|h)$ berücksichtigt

- Problem mit kleinen Faktoren: **Logarithmus**, Übergang zu Summe
- **Zero-Frequency-Problem**: Laplace-Glättung mit $\alpha = 1$
- Klassifikation von **Out-of-Vocabulary-Termen**: UNK-Term trainieren

Unless otherwise noted, this work is licensed under CC BY-SA 4.0.

Last modified: *b309587 (lecture: add video (NB3), 2025-10-01)*