

# NB: Text-Klassifikation mit Naive Bayes

---

Carsten Gips (HSBI)

Unless otherwise noted, this work is licensed under CC BY-SA 4.0.

# Textklassifikation mit NB

- Trainingsdaten: Mails, manuell markiert:
  - D1: ("Die sieben Zwerge fraßen die sieben Ziegen", OK)
  - D2: ("Die sieben Ziegen traten die sieben Wölfe", SPAM)
  - D3: ("Die sieben Wölfe fraßen die sieben Böcke", OK)
  - D4: ("Die sieben Böcke traten die sieben Zwerge", OK)
- Testdaten (neue Mails):
  - T1: ("Die sieben Zwerge fraßen die sieben Wölfe")

Lernen Sie mit Hilfe der Trainingsmenge einen Naive-Bayes-Klassifikator und wenden Sie diesen auf die Test-Dokumente an.

- Vereinheitlichung: Kleinbuchstaben
- **Tokenisierung**: Aufteilung auf einzelne Wörter
- **Stop Words** entfernen: “der”, “die”, “das”, ...
- **Lemmatisierung**: “fraßen” -> “fressen”, “Wölfe” -> “Wolf”, ...
- **Synonyme, Homonyme, Akronyme** ersetzen
- **Stemming**
- **Terme**: Die erhaltenen Wörter nennen wir “Terme”.

Nach Vorverarbeitung:

- Trainingsdaten (**Terme**):
  - D1: (sieben, zwerg, fressen, sieben, ziege; OK)
  - D2: (sieben, ziege, treten, sieben, wolf; SPAM)
  - D3: (sieben, wolf, fressen, sieben, bock; OK)
  - D4: (sieben, bock, treten, sieben, zwerg; OK)
- Testdaten (**Terme**):
  - T1: (sieben, zwerg, fressen, sieben, wolf)

# Merkmalsvektor: Bag of Words

Nach Vorverarbeitung:

- Trainingsdaten (**Terme**):
  - D1: (sieben, zwerg, fressen, sieben, ziege; OK)
  - D2: (sieben, ziege, treten, sieben, wolf; SPAM)
  - D3: (sieben, wolf, fressen, sieben, bock; OK)
  - D4: (sieben, bock, treten, sieben, zwerg; OK)
- Testdaten (**Terme**):
  - T1: (sieben, zwerg, fressen, sieben, wolf)

**Vokabular:**  $V = \{\text{sieben, zwerg, fressen, ziege, treten, wolf, bock}\}$

**Bag of Words:** Merkmalsvektor mit fester Anordnung des Vokabulars

## Bag of Words für Trainingsdaten

- D1: (sieben, zwerg, fressen, sieben, ziege; OK)
- D2: (sieben, ziege, treten, sieben, wolf; SPAM)
- D3: (sieben, wolf, fressen, sieben, bock; OK)
- D4: (sieben, bock, treten, sieben, zwerg; OK)

|    | sieben | zwerg | fressen | ziege | treten | wolf | bock | Klasse |
|----|--------|-------|---------|-------|--------|------|------|--------|
| D1 | 2      | 1     | 1       | 1     | 0      | 0    | 0    | OK     |
| D2 | 2      | 0     | 0       | 1     | 1      | 1    | 0    | SPAM   |
| D3 | 2      | 0     | 1       | 0     | 0      | 1    | 1    | OK     |
| D4 | 2      | 1     | 0       | 0     | 1      | 0    | 1    | OK     |

## Naive Bayes Training (Multinomial NB)

|    | sieben | zweig | fressen | ziege | treten | wolf | bock | Klasse |
|----|--------|-------|---------|-------|--------|------|------|--------|
| D1 | 2      | 1     | 1       | 1     | 0      | 0    | 0    | OK     |
| D2 | 2      | 0     | 0       | 1     | 1      | 1    | 0    | SPAM   |
| D3 | 2      | 0     | 1       | 0     | 0      | 1    | 1    | OK     |
| D4 | 2      | 1     | 0       | 0     | 1      | 0    | 1    | OK     |

| Klasse | sieben | zweig | fressen | ziege | treten | wolf | bock | Anzahl<br>Wörter | Anzahl<br>Dokumente |
|--------|--------|-------|---------|-------|--------|------|------|------------------|---------------------|
| OK     | 6      | 2     | 2       | 1     | 1      | 1    | 2    | 15               | 3                   |
| SPAM   | 2      | 0     | 0       | 1     | 1      | 1    | 0    | 5                | 1                   |

## Naive Bayes Training (Multinomial NB), cnt.

| Klasse | sieben | zwerg | fressen | ziege | treten | wolf | bock | Anzahl<br>Wörter | Anzahl<br>Dokumente |
|--------|--------|-------|---------|-------|--------|------|------|------------------|---------------------|
| OK     | 6      | 2     | 2       | 1     | 1      | 1    | 2    | 15               | 3                   |
| SPAM   | 2      | 0     | 0       | 1     | 1      | 1    | 0    | 5                | 1                   |

Naive Bayes “trainieren”

- A-priori-Wahrscheinlichkeit der Klassen:

$$P(c) = \frac{N_c}{N} = \frac{\text{Anzahl Dokumente in Klasse } c}{\text{Anzahl Dokumente}}$$

- Likelihood der Daten (Terme):

$$P(t | c) = \frac{\text{count}(t, c)}{\sum_{v \in V} \text{count}(v, c)}$$

mit  $\text{count}(t, c)$  Anzahl der Vorkommen von Term  $t$  in allen Dokumenten der Klasse  $c$  und  $V$  die Vereinigung aller Terme aller Dokumente (Vokabular)

- A-priori-Wahrscheinlichkeit:

- $P(\text{OK}) = 3/4 = 0.75$

- $P(\text{SPAM}) = 1/4 = 0.25$

- Likelihood:

- $P(\text{sieben} | \text{OK}) = (2 + 2 + 2)/(2 + 2 + 2 + 1 + 1 + 1 + 1 + 1 + 1 + 1 + 1) = 6/15 = 0.40$

- $P(\text{sieben} | \text{SPAM}) = (2)/(2 + 1 + 1 + 1) = 2/5 = 0.40$

- $P(\text{zwerg} | \text{OK}) = 2/15 = 0.133$

- $P(\text{zwerg} | \text{SPAM}) = 0/5 = 0.00$

- $P(\text{fressen} | \text{OK}) = 2/15 = 0.133$

- $P(\text{fressen} | \text{SPAM}) = 0/5 = 0.00$

- $P(\text{ziege} | \text{OK}) = 1/15 = 0.067$



## Naive Bayes Klassifikation (Multinomial NB)

$$h_{MAP} = \operatorname{argmax}_{h \in H} P(h) \prod_{x \in \mathbf{x}} P(x \mid h)$$

# Naive Bayes Klassifikation (Multinomial NB)

$$h_{MAP} = \operatorname{argmax}_{h \in H} P(h) \prod_{x \in \mathbf{x}} P(x | h)$$

Jedes Vorkommen eines Wortes im Testdatensatz ist ein  $x$ !

$$h_{MAP} = \operatorname{argmax}_{h \in H} P(h) \prod_{w \in \mathbf{V}: \text{count}(w) > 0} P(w | h)^{\text{count}(w)}$$

T1: (sieben, zwerg, fressen, sieben, wolf)

- **h = OK:**  $P(\text{OK}) \cdot P(\text{sieben} | \text{OK})^2 \cdot P(\text{zwerg} | \text{OK})^1 \cdot P(\text{fressen} | \text{OK})^1 \cdot P(\text{ziege} | \text{OK})^0 \cdot P(\text{treten} | \text{OK})^0 \cdot P(\text{wolf} | \text{OK})^1 \cdot P(\text{bock} | \text{OK})^0$   
 $= 0.75 * 0.40 * 0.40 * 0.133 * 0.133 * 1 * 1 * 0.067 * 1 = 0.00014221956$
- **h = SPAM:**  $P(\text{SPAM}) \cdot P(\text{sieben} | \text{SPAM})^2 \cdot P(\text{zwerg} | \text{SPAM})^1 \cdot P(\text{fressen} | \text{SPAM})^1 \cdot P(\text{ziege} | \text{SPAM})^0 \cdot P(\text{treten} | \text{SPAM})^0 \cdot P(\text{wolf} | \text{SPAM})^1 \cdot P(\text{bock} | \text{SPAM})^0$   
 $= 0.25 * 0.40 * 0.40 * 0.00 * 0.00 * 1 * 1 * 0.20 * 1 = 0.00$

Entscheidung: OK

# Naive Bayes mit Laplace-Glättung (Multinomial NB)

$$P(t \mid c) = \frac{\text{count}(t, c) + \alpha}{\sum_{v \in V} \text{count}(v, c) + \alpha \cdot |V|}, \quad \text{bei Laplace: } \alpha = 1$$

- A-priori-Wahrscheinlichkeit:
  - $P(\text{OK}) = 3/4 = 0.75$
  - $P(\text{SPAM}) = 1/4 = 0.25$
- Likelihood:
  - $P(\text{sieben} \mid \text{OK}) = (2 + 2 + 2 + \mathbf{1}) / (2 + 2 + 2 + 1 + 1 + 1 + 1 + 1 + 1 + 1 + 1 + \mathbf{7}) = 7/22 = 0.318$   
(vorher: 0.40)
  - $P(\text{sieben} \mid \text{SPAM}) = (2 + \mathbf{1}) / (2 + 1 + 1 + 1 + \mathbf{7}) = 3/12 = 0.25$  (vorher: 0.40)
  - $P(\text{zwerg} \mid \text{OK}) = (2 + \mathbf{1}) / (15 + \mathbf{7}) = 0.136$  (vorher: 0.133)
  - $P(\text{zwerg} \mid \text{SPAM}) = (0 + \mathbf{1}) / (5 + \mathbf{7}) = 0.083$  (vorher: **0.00**)
  - $P(\text{fressen} \mid \text{OK}) = (2 + \mathbf{1}) / (15 + \mathbf{7}) = 0.136$  (vorher: 0.133)
  - $P(\text{fressen} \mid \text{SPAM}) = (0 + \mathbf{1}) / (5 + \mathbf{7}) = 0.083$  (vorher: **0.00**)
  - $P(\text{ziege} \mid \text{OK}) = (1 + \mathbf{1}) / (15 + \mathbf{7}) = 0.091$  (vorher: 0.067)
  - $P(\text{ziege} \mid \text{SPAM}) = (1 + \mathbf{1}) / (5 + \mathbf{7}) = 0.167$  (vorher: 0.20)
  - $P(\text{treten} \mid \text{OK}) = (1 + \mathbf{1}) / (15 + \mathbf{7}) = 0.091$  (vorher: 0.067)
  - $P(\text{treten} \mid \text{SPAM}) = (1 + \mathbf{1}) / (5 + \mathbf{7}) = 0.167$  (vorher: 0.20)
  - $P(\text{wolf} \mid \text{OK}) = (1 + \mathbf{1}) / (15 + \mathbf{7}) = 0.091$  (vorher: 0.067)

## Naive Bayes mit Laplace-Glättung (Multinomial NB), cnt.

T1: (sieben, zwerg, fressen, sieben, wolf)

- **h = OK:**  $P(\text{OK}) \cdot P(\text{sieben} \mid \text{OK})^2 \cdot P(\text{zwerg} \mid \text{OK})^1 \cdot P(\text{fressen} \mid \text{OK})^1 \cdot P(\text{ziege} \mid \text{OK})^0 \cdot P(\text{treten} \mid \text{OK})^0 \cdot P(\text{wolf} \mid \text{OK})^1 \cdot P(\text{bock} \mid \text{OK})^0$   
 $= 0.75 * 0.318 * 0.318 * 0.136 * 0.136 * 1 * 1 * 0.091 * 1 = 0.0001276540836$  (vorher: 0.00014221956)
- **h = SPAM:**  $P(\text{SPAM}) \cdot P(\text{sieben} \mid \text{SPAM})^2 \cdot P(\text{zwerg} \mid \text{SPAM})^1 \cdot P(\text{fressen} \mid \text{SPAM})^1 \cdot P(\text{ziege} \mid \text{SPAM})^0 \cdot P(\text{treten} \mid \text{SPAM})^0 \cdot P(\text{wolf} \mid \text{SPAM})^1 \cdot P(\text{bock} \mid \text{SPAM})^0$   
 $= 0.25 * 0.25 * 0.25 * 0.083 * 0.083 * 1 * 1 * 0.167 * 1 = 0.00001797598438$  (vorher: **0.00**)

Entscheidung: OK

# Naive Bayes mit Out-of-Vocabulary-Termen (OOV, Multinomial NB)

T1: (sieben, zwerg, fressen, sieben, wolf, **lecker**)

- **h = OK:**  $P(\text{OK}) \cdot P(\text{sieben} \mid \text{OK})^2 \cdot P(\text{zwerg} \mid \text{OK})^1 \cdot P(\text{fressen} \mid \text{OK})^1 \cdot P(\text{ziege} \mid \text{OK})^0 \cdot P(\text{treten} \mid \text{OK})^0 \cdot P(\text{wolf} \mid \text{OK})^1 \cdot P(\text{bock} \mid \text{OK})^0 \cdot \mathbf{P}(\text{lecker} \mid \text{OK})^1$
- **h = SPAM:**  $P(\text{SPAM}) \cdot P(\text{sieben} \mid \text{SPAM})^2 \cdot P(\text{zwerg} \mid \text{SPAM})^1 \cdot P(\text{fressen} \mid \text{SPAM})^1 \cdot P(\text{ziege} \mid \text{SPAM})^0 \cdot P(\text{treten} \mid \text{SPAM})^0 \cdot P(\text{wolf} \mid \text{SPAM})^1 \cdot P(\text{bock} \mid \text{SPAM})^0 \cdot \mathbf{P}(\text{lecker} \mid \text{SPAM})^1$

$\mathbf{P}(\text{lecker} \mid \text{OK})$  und  $\mathbf{P}(\text{lecker} \mid \text{SPAM})$  sind **unbekannt!**

## Möglichkeiten:

1. Da im Training nicht vorgekommen: 0 als Wert für  $P(\text{lecker} \mid c)$  annehmen
2. Term ignorieren
3. Ad-hoc Laplace einführen
4. Mit UNK-Term arbeiten im Training/Klassifikation

## Naive Bayes mit UNK-Term (OOV, Multinomial NB)

## Training

| Klasse | sieben | zwerger | fressen | ziege | treten | wolf | bock | UNK | Anzahl Wörter | Anzahl Dokumente |
|--------|--------|---------|---------|-------|--------|------|------|-----|---------------|------------------|
| OK     | 6      | 2       | 2       | 1     | 1      | 1    | 2    | 0   | 15            | 3                |
| SPAM   | 2      | 0       | 0       | 1     | 1      | 1    | 0    | 0   | 5             | 1                |

- A-priori-Wahrscheinlichkeit:
  - $P(\text{OK}) = 3/4 = 0.75$
  - $P(\text{SPAM}) = 1/4 = 0.25$
- Likelihood:
  - $P(\text{sieben} \mid \text{OK}) = (2 + 2 + 2 + 1)/(2 + 2 + 2 + 1 + 1 + 1 + 1 + 1 + 1 + 1 + 1 + 1 + \mathbf{8}) = 7/23 = 0.304$   
(vorher: 0.318)
  - $P(\text{sieben} \mid \text{SPAM}) = (2 + 1)/(2 + 1 + 1 + 1 + \mathbf{8}) = 3/13 = 0.231$  (vorher: 0.25)
  - ...
  - $P(\text{UNK} \mid \text{OK}) = (0 + 1)/(15 + \mathbf{8}) = 0.043$
  - $P(\text{UNK} \mid \text{SPAM}) = (0 + 1)/(5 + \mathbf{8}) = 0.077$

## Klassifikation

T1: (sieben, zwerg, fressen, sieben, wolf, **lecker**)

- **h = OK:**  $P(\text{OK}) \cdot P(\text{sieben} \mid \text{OK})^2 \cdot P(\text{zwerg} \mid \text{OK})^1 \cdot P(\text{fressen} \mid \text{OK})^1 \cdot P(\text{ziege} \mid \text{OK})^0 \cdot P(\text{treten} \mid \text{OK})^0 \cdot P(\text{wolf} \mid \text{OK})^1 \cdot P(\text{bock} \mid \text{OK})^0 \cdot \mathbf{P}(\text{lecker} \mid \text{OK})^1$
- **h = SPAM:**  $P(\text{SPAM}) \cdot P(\text{sieben} \mid \text{SPAM})^2 \cdot P(\text{zwerg} \mid \text{SPAM})^1 \cdot P(\text{fressen} \mid \text{SPAM})^1 \cdot P(\text{ziege} \mid \text{SPAM})^0 \cdot P(\text{treten} \mid \text{SPAM})^0 \cdot P(\text{wolf} \mid \text{SPAM})^1 \cdot P(\text{bock} \mid \text{SPAM})^0 \cdot \mathbf{P}(\text{lecker} \mid \text{SPAM})^1$

## Mapping:

- $P(\text{lecker} \mid \text{OK}) \Rightarrow P(\text{UNK} \mid \text{OK}) = 0.043$
- $P(\text{lecker} \mid \text{SPAM}) \Rightarrow P(\text{UNK} \mid \text{SPAM}) = 0.077$

## Naive Bayes Training (Bernoulli NB, mit Laplace)

|    | sieben | zweig | fressen | ziege | treten | wolf | bock | Klasse |
|----|--------|-------|---------|-------|--------|------|------|--------|
| D1 | 1      | 1     | 1       | 1     | 0      | 0    | 0    | OK     |
| D2 | 1      | 0     | 0       | 1     | 1      | 1    | 0    | SPAM   |
| D3 | 1      | 0     | 1       | 0     | 0      | 1    | 1    | OK     |
| D4 | 1      | 1     | 0       | 0     | 1      | 0    | 1    | OK     |

| Klasse | sieben | zweig | fressen | ziege | treten | wolf | bock | Anzahl Dokumente |
|--------|--------|-------|---------|-------|--------|------|------|------------------|
| OK     | 3      | 2     | 2       | 1     | 1      | 1    | 2    | 3                |
| SPAM   | 1      | 0     | 0       | 1     | 1      | 1    | 0    | 1                |



## Naive Bayes Training (Bernoulli NB, mit Laplace), cnt.

| Klasse | sieben | zwerg | fressen | ziege | treten | wolf | bock | Anzahl Dokumente |
|--------|--------|-------|---------|-------|--------|------|------|------------------|
| OK     | 3      | 2     | 2       | 1     | 1      | 1    | 2    | 3                |
| SPAM   | 1      | 0     | 0       | 1     | 1      | 1    | 0    | 1                |

Naive Bayes "trainieren"

- A-priori-Wahrscheinlichkeit der Klassen:

$$P(c) = \frac{N_c}{N} = \frac{\text{Anzahl Dokumente in Klasse } c}{\text{Anzahl Dokumente}}$$

- Likelihood der Daten (Terme):

- $P(t = 1 | c) = \frac{\text{Anzahl Dokumente in Klasse } c \text{ mit Term } t + \alpha}{\text{Anzahl Dokumente in Klasse } c + 2 \cdot \alpha}$
- $P(t = 0 | c) = 1 - P(t = 1 | c)$

- A-priori-Wahrscheinlichkeit:

- $P(\text{OK}) = 3/4 = 0.75$
- $P(\text{SPAM}) = 1/4 = 0.25$

- Likelihood  $\alpha = 1$ :

- $P(\text{sieben} = 1 | \text{OK}) = (3 + 1)/(3 + 2) = 4/5 = 0.80$
- $P(\text{sieben} = 1 | \text{SPAM}) = (1 + 1)/(1 + 2) = 2/3 = 0.667$
- $P(\text{zwerg} = 1 | \text{OK}) = 3/5 = 0.60$
- $P(\text{zwerg} = 1 | \text{SPAM}) = 1/3 = 0.333$
- $P(\text{fressen} = 1 | \text{OK}) = 3/5 = 0.60$
- $P(\text{fressen} = 1 | \text{SPAM}) = 1/3 = 0.333$
- $P(\text{ziege} = 1 | \text{OK}) = 2/5 = 0.40$
- $P(\text{ziege} = 1 | \text{SPAM}) = 2/3 = 0.667$
- $P(\text{treten} = 1 | \text{OK}) = 2/5 = 0.40$

## Naive Bayes Klassifikation (Bernoulli NB)

$$h_{MAP} = \operatorname{argmax}_{h \in H} P(h) \prod_{x \in \mathbf{x}} P(x \mid h)$$

# Naive Bayes Klassifikation (Bernoulli NB)

$$h_{MAP} = \operatorname{argmax}_{h \in H} P(h) \prod_{x \in \mathbf{x}} P(x | h)$$

Für jedes Wort  $w$  im Vokabular  $V$  gibt es die Beobachtung (Bernoulli-Variable)  $lw \in \{0, 1\}$ .

$$h_{MAP} = \operatorname{argmax}_{h \in H} P(h) \prod_{w \in V} P(lw = 1 | h)^{lw} \cdot (1 - P(lw = 1 | h))^{1-lw}$$

T1: (sieben, zwerg, fressen, sieben, wolf)

- **h = OK:**  $P(\text{OK}) \cdot P(\text{sieben} = 1 | \text{OK}) \cdot P(\text{zwerg} = 1 | \text{OK}) \cdot P(\text{fressen} = 1 | \text{OK}) \cdot P(\text{ziege} = 0 | \text{OK}) \cdot P(\text{treten} = 0 | \text{OK}) \cdot P(\text{wolf} = 1 | \text{OK}) \cdot P(\text{bock} = 0 | \text{OK})$   
 $= 0.75 * 0.80 * 0.60 * 0.60 * (1 - 0.40) * (1 - 0.40) * 0.40 * (1 - 0.60) = 0.0124416$
- **h = SPAM:**  $P(\text{SPAM}) \cdot P(\text{sieben} = 1 | \text{SPAM}) \cdot P(\text{zwerg} = 1 | \text{SPAM}) \cdot P(\text{fressen} = 1 | \text{SPAM}) \cdot P(\text{ziege} = 0 | \text{SPAM}) \cdot P(\text{treten} = 0 | \text{SPAM}) \cdot P(\text{wolf} = 1 | \text{SPAM}) \cdot P(\text{bock} = 0 | \text{SPAM})$   
 $= 0.25 * 0.667 * 0.333 * 0.333 * (1 - 0.667) * (1 - 0.667) * 0.667 * (1 - 0.333) = 0.0009122091926$

Entscheidung: OK

# Wrap-Up

- **Vorverarbeitung:** Tokenisierung, Vokabular, Bag of Words (BoW)

- **Multinomial NB:**

- Zähle die Vorkommen eines Terms:  $P(t \mid c) = \frac{\text{count}(t, c) + \alpha}{\sum_{v \in V} \text{count}(v, c) + \alpha \cdot |V|}$
- Klassifikation mit  $h_{MAP} = \operatorname{argmax}_{h \in H} P(h) \prod_{w \in V} P(w \mid h)^{\text{count}(w)}$
- Im Test nicht vorhandene Terme  $t$  aus  $V$  werden ignoriert (Faktor 1)

- **Bernoulli NB:**

- Prüfe das Vorkommen eines Terms:  $P(t = 1 \mid c) = \frac{\text{Anzahl Dokumente in Klasse } c \text{ mit Term } t + \alpha}{\text{Anzahl Dokumente in Klasse } c + 2 \cdot \alpha}$
- Klassifikation mit  $h_{MAP} = \operatorname{argmax}_{h \in H} P(h) \prod_{w \in V} P(lw = 1 \mid h)^{l_w} \cdot (1 - P(lw = 1 \mid h))^{1-l_w}$
- Im Test nicht vorhandene Terme  $t$  aus  $V$  werden korrekt mit  $P(lw = 0 \mid h)$  berücksichtigt

- Problem mit kleinen Faktoren: **Logarithmus**, Übergang zu Summe
- **Zero-Frequency-Problem:** Laplace-Glättung mit  $\alpha = 1$
- Klassifikation von **Out-of-Vocabulary-Termen:** UNK-Term trainieren



Unless otherwise noted, this work is licensed under CC BY-SA 4.0.

