

NB3: Text-Klassifikation mit Naive Bayes

Carsten Gips (HSBI)

Unless otherwise noted, this work is licensed under CC BY-SA 4.0.

Textklassifikation mit NB

- Trainingsdaten: Mails, manuell markiert:
 - D1: ("Die sieben Zwerge fraßen die sieben Ziegen", OK)
 - D2: ("Die sieben Ziegen traten die sieben Wölfe", SPAM)
 - D3: ("Die sieben Wölfe fraßen die sieben Böcke", OK)
 - D4: ("Die sieben Böcke traten die sieben Zwerge", OK)
- Testdaten (neue Mails):
 - T1: ("Die sieben Zwerge fraßen die sieben Wölfe")

Lernen Sie mit Hilfe der Trainingsmenge einen Naive-Bayes-Klassifikator und wenden Sie diesen auf die Test-Dokumente an.

- Vereinheitlichung: Kleinbuchstaben
- **Tokenisierung**: Aufteilung auf einzelne Wörter
- **Stop Words** entfernen: “der”, “die”, “das”, ...
- **Lemmatisierung**: “fraßen” → “fressen”, “Wölfe” → “Wolf”, ...
- **Synonyme, Homonyme, Akronyme** ersetzen
- **Stemming**
- **Terme**: Die erhaltenen Wörter nennen wir “Terme”.

Nach Vorverarbeitung:

- Trainingsdaten (**Terme**):
 - D1: (sieben, zwerg, fressen, sieben, ziege; OK)
 - D2: (sieben, ziege, treten, sieben, wolf; SPAM)
 - D3: (sieben, wolf, fressen, sieben, bock; OK)
 - D4: (sieben, bock, treten, sieben, zwerg; OK)
- Testdaten (**Terme**):
 - T1: (sieben, zwerg, fressen, sieben, wolf)

Merkmalsvektor: Bag of Words

Nach Vorverarbeitung:

- Trainingsdaten (**Terme**):
 - D1: (sieben, zwerg, fressen, sieben, ziege; OK)
 - D2: (sieben, ziege, treten, sieben, wolf; SPAM)
 - D3: (sieben, wolf, fressen, sieben, bock; OK)
 - D4: (sieben, bock, treten, sieben, zwerg; OK)
- Testdaten (**Terme**):
 - T1: (sieben, zwerg, fressen, sieben, wolf)

Vokabular: $V = \{\text{sieben, zwerg, fressen, ziege, treten, wolf, bock}\}$

Bag of Words: Merkmalsvektor mit fester Anordnung des Vokabulars

Bag of Words für Trainingsdaten

- D1: (sieben, zwerg, fressen, sieben, ziege; OK)
- D2: (sieben, ziege, treten, sieben, wolf; SPAM)
- D3: (sieben, wolf, fressen, sieben, bock; OK)
- D4: (sieben, bock, treten, sieben, zwerg; OK)

	sieben	zwerg	fressen	ziege	treten	wolf	bock	Klasse
D1	2	1	1	1	0	0	0	OK
D2	2	0	0	1	1	1	0	SPAM
D3	2	0	1	0	0	1	1	OK
D4	2	1	0	0	1	0	1	OK

Naive Bayes Training (Multinomial NB)

	sieben	zweig	fressen	ziege	treten	wolf	bock	Klasse
D1	2	1	1	1	0	0	0	OK
D2	2	0	0	1	1	1	0	SPAM
D3	2	0	1	0	0	1	1	OK
D4	2	1	0	0	1	0	1	OK

Klasse	sieben	zweig	fressen	ziege	treten	wolf	bock	Anzahl Wörter	Anzahl Dokumente
OK	6	2	2	1	1	1	2	15	3
SPAM	2	0	0	1	1	1	0	5	1

Naive Bayes Training (Multinomial NB), cnt.

Klasse	sieben	zwerg	fressen	ziege	treten	wolf	bock	Anzahl Wörter	Anzahl Dokumente
OK	6	2	2	1	1	1	2	15	3
SPAM	2	0	0	1	1	1	0	5	1

Naive Bayes “trainieren”

- A-priori-Wahrscheinlichkeit der Klassen:

$$P(c) = \frac{N_c}{N} = \frac{\text{Anzahl Dokumente in Klasse } c}{\text{Anzahl Dokumente}}$$

- Likelihood der Daten (Terme):

$$P(t | c) = \frac{\text{count}(t, c)}{\sum_{v \in V} \text{count}(v, c)}$$

mit $\text{count}(t, c)$ Anzahl der Vorkommen von Term t in allen Dokumenten der Klasse c und V die Vereinigung aller Terme aller Dokumente (Vokabular)

- A-priori-Wahrscheinlichkeit:

- $P(\text{OK}) = 3/4 = 0.75$

- $P(\text{SPAM}) = 1/4 = 0.25$

- Likelihood:

- $P(\text{sieben} | \text{OK}) = (2 + 2 + 2)/(2 + 2 + 2 + 1 + 1 + 1 + 1 + 1 + 1 + 1 + 1) = 6/15 = 0.40$

- $P(\text{sieben} | \text{SPAM}) = (2)/(2 + 1 + 1 + 1) = 2/5 = 0.40$

- $P(\text{zwerg} | \text{OK}) = 2/15 = 0.133$

- $P(\text{zwerg} | \text{SPAM}) = 0/5 = 0.00$

- $P(\text{fressen} | \text{OK}) = 2/15 = 0.133$

- $P(\text{fressen} | \text{SPAM}) = 0/5 = 0.00$

- $P(\text{ziege} | \text{OK}) = 1/15 = 0.067$

Naive Bayes Klassifikation (Multinomial NB)

$$h_{MAP} = \operatorname{argmax}_{h \in H} P(h) \prod_{x \in \mathbf{x}} P(x \mid h)$$

Naive Bayes Klassifikation (Multinomial NB)

$$h_{MAP} = \operatorname{argmax}_{h \in H} P(h) \prod_{x \in \mathbf{x}} P(x | h)$$

Jedes Vorkommen eines Wortes im Testdatensatz ist ein x !

$$h_{MAP} = \operatorname{argmax}_{h \in H} P(h) \prod_{w \in \mathbf{V}: \text{count}(w) > 0} P(w | h)^{\text{count}(w)}$$

T1: (sieben, zwerg, fressen, sieben, wolf)

- **h = OK:** $P(\text{OK}) \cdot P(\text{sieben} | \text{OK})^2 \cdot P(\text{zwerg} | \text{OK})^1 \cdot P(\text{fressen} | \text{OK})^1 \cdot P(\text{ziege} | \text{OK})^0 \cdot P(\text{treten} | \text{OK})^0 \cdot P(\text{wolf} | \text{OK})^1 \cdot P(\text{bock} | \text{OK})^0$
 $= 0.75 * 0.40 * 0.40 * 0.133 * 0.133 * 1 * 1 * 0.067 * 1 = 0.00014221956$
- **h = SPAM:** $P(\text{SPAM}) \cdot P(\text{sieben} | \text{SPAM})^2 \cdot P(\text{zwerg} | \text{SPAM})^1 \cdot P(\text{fressen} | \text{SPAM})^1 \cdot P(\text{ziege} | \text{SPAM})^0 \cdot P(\text{treten} | \text{SPAM})^0 \cdot P(\text{wolf} | \text{SPAM})^1 \cdot P(\text{bock} | \text{SPAM})^0$
 $= 0.25 * 0.40 * 0.40 * 0.00 * 0.00 * 1 * 1 * 0.20 * 1 = 0.00$

Entscheidung: OK

Naive Bayes mit Laplace-Glättung (Multinomial NB)

$$P(t \mid c) = \frac{\text{count}(t, c) + \alpha}{\sum_{v \in V} \text{count}(v, c) + \alpha \cdot |V|}, \quad \text{bei Laplace: } \alpha = 1$$

- A-priori-Wahrscheinlichkeit:
 - $P(\text{OK}) = 3/4 = 0.75$
 - $P(\text{SPAM}) = 1/4 = 0.25$
- Likelihood:
 - $P(\text{sieben} \mid \text{OK}) = (2 + 2 + 2 + \mathbf{1}) / (2 + 2 + 2 + 1 + 1 + 1 + 1 + 1 + 1 + 1 + 1 + \mathbf{7}) = 7/22 = 0.318$
(vorher: 0.40)
 - $P(\text{sieben} \mid \text{SPAM}) = (2 + \mathbf{1}) / (2 + 1 + 1 + 1 + \mathbf{7}) = 3/12 = 0.25$ (vorher: 0.40)
 - $P(\text{zwerg} \mid \text{OK}) = (2 + \mathbf{1}) / (15 + \mathbf{7}) = 0.136$ (vorher: 0.133)
 - $P(\text{zwerg} \mid \text{SPAM}) = (0 + \mathbf{1}) / (5 + \mathbf{7}) = 0.083$ (vorher: **0.00**)
 - $P(\text{fressen} \mid \text{OK}) = (2 + \mathbf{1}) / (15 + \mathbf{7}) = 0.136$ (vorher: 0.133)
 - $P(\text{fressen} \mid \text{SPAM}) = (0 + \mathbf{1}) / (5 + \mathbf{7}) = 0.083$ (vorher: **0.00**)
 - $P(\text{ziege} \mid \text{OK}) = (1 + \mathbf{1}) / (15 + \mathbf{7}) = 0.091$ (vorher: 0.067)
 - $P(\text{ziege} \mid \text{SPAM}) = (1 + \mathbf{1}) / (5 + \mathbf{7}) = 0.167$ (vorher: 0.20)
 - $P(\text{treten} \mid \text{OK}) = (1 + \mathbf{1}) / (15 + \mathbf{7}) = 0.091$ (vorher: 0.067)
 - $P(\text{treten} \mid \text{SPAM}) = (1 + \mathbf{1}) / (5 + \mathbf{7}) = 0.167$ (vorher: 0.20)
 - $P(\text{wolf} \mid \text{OK}) = (1 + \mathbf{1}) / (15 + \mathbf{7}) = 0.091$ (vorher: 0.067)

Naive Bayes mit Laplace-Glättung (Multinomial NB), cnt.

T1: (sieben, zwerg, fressen, sieben, wolf)

- **h = OK:** $P(\text{OK}) \cdot P(\text{sieben} \mid \text{OK})^2 \cdot P(\text{zwerg} \mid \text{OK})^1 \cdot P(\text{fressen} \mid \text{OK})^1 \cdot P(\text{ziege} \mid \text{OK})^0 \cdot P(\text{treten} \mid \text{OK})^0 \cdot P(\text{wolf} \mid \text{OK})^1 \cdot P(\text{bock} \mid \text{OK})^0$
 $= 0.75 * 0.318 * 0.318 * 0.136 * 0.136 * 1 * 1 * 0.091 * 1 = 0.0001276540836$ (vorher: 0.00014221956)
- **h = SPAM:** $P(\text{SPAM}) \cdot P(\text{sieben} \mid \text{SPAM})^2 \cdot P(\text{zwerg} \mid \text{SPAM})^1 \cdot P(\text{fressen} \mid \text{SPAM})^1 \cdot P(\text{ziege} \mid \text{SPAM})^0 \cdot P(\text{treten} \mid \text{SPAM})^0 \cdot P(\text{wolf} \mid \text{SPAM})^1 \cdot P(\text{bock} \mid \text{SPAM})^0$
 $= 0.25 * 0.25 * 0.25 * 0.083 * 0.083 * 1 * 1 * 0.167 * 1 = 0.00001797598438$ (vorher: **0.00**)

Entscheidung: OK

Naive Bayes mit Out-of-Vocabulary-Termen (OOV, Multinomial NB)

T1: (sieben, zwerg, fressen, sieben, wolf, **lecker**)

- **h = OK:** $P(\text{OK}) \cdot P(\text{sieben} \mid \text{OK})^2 \cdot P(\text{zwerg} \mid \text{OK})^1 \cdot P(\text{fressen} \mid \text{OK})^1 \cdot P(\text{ziege} \mid \text{OK})^0 \cdot P(\text{treten} \mid \text{OK})^0 \cdot P(\text{wolf} \mid \text{OK})^1 \cdot P(\text{bock} \mid \text{OK})^0 \cdot \mathbf{P}(\text{lecker} \mid \text{OK})^1$
- **h = SPAM:** $P(\text{SPAM}) \cdot P(\text{sieben} \mid \text{SPAM})^2 \cdot P(\text{zwerg} \mid \text{SPAM})^1 \cdot P(\text{fressen} \mid \text{SPAM})^1 \cdot P(\text{ziege} \mid \text{SPAM})^0 \cdot P(\text{treten} \mid \text{SPAM})^0 \cdot P(\text{wolf} \mid \text{SPAM})^1 \cdot P(\text{bock} \mid \text{SPAM})^0 \cdot \mathbf{P}(\text{lecker} \mid \text{SPAM})^1$

$\mathbf{P}(\text{lecker} \mid \text{OK})$ und $\mathbf{P}(\text{lecker} \mid \text{SPAM})$ sind **unbekannt!**

Möglichkeiten:

1. Da im Training nicht vorgekommen: 0 als Wert für $P(\text{lecker} \mid c)$ annehmen
2. Term ignorieren
3. Ad-hoc Laplace einführen
4. Mit UNK-Term arbeiten im Training/Klassifikation

Naive Bayes mit UNK-Term (OOV, Multinomial NB)

Training

Klasse	sieben	zwerger	fressen	ziege	treten	wolf	bock	UNK	Anzahl Wörter	Anzahl Dokumente
OK	6	2	2	1	1	1	2	0	15	3
SPAM	2	0	0	1	1	1	0	0	5	1

- A-priori-Wahrscheinlichkeit:
 - $P(\text{OK}) = 3/4 = 0.75$
 - $P(\text{SPAM}) = 1/4 = 0.25$
- Likelihood:
 - $P(\text{sieben} \mid \text{OK}) = (2 + 2 + 2 + 1)/(2 + 2 + 2 + 1 + 1 + 1 + 1 + 1 + 1 + 1 + 1 + 1 + 1 + \mathbf{8}) = 7/23 = 0.304$
(vorher: 0.318)
 - $P(\text{sieben} \mid \text{SPAM}) = (2 + 1)/(2 + 1 + 1 + 1 + \mathbf{8}) = 3/13 = 0.231$ (vorher: 0.25)
 - ...
 - $P(\text{UNK} \mid \text{OK}) = (0 + 1)/(15 + \mathbf{8}) = 0.043$
 - $P(\text{UNK} \mid \text{SPAM}) = (0 + 1)/(5 + \mathbf{8}) = 0.077$

Klassifikation

T1: (sieben, zwerg, fressen, sieben, wolf, **lecker**)

- **h = OK:** $P(\text{OK}) \cdot P(\text{sieben} \mid \text{OK})^2 \cdot P(\text{zwerg} \mid \text{OK})^1 \cdot P(\text{fressen} \mid \text{OK})^1 \cdot P(\text{ziege} \mid \text{OK})^0 \cdot P(\text{treten} \mid \text{OK})^0 \cdot P(\text{wolf} \mid \text{OK})^1 \cdot P(\text{bock} \mid \text{OK})^0 \cdot \mathbf{P}(\text{lecker} \mid \text{OK})^1$
- **h = SPAM:** $P(\text{SPAM}) \cdot P(\text{sieben} \mid \text{SPAM})^2 \cdot P(\text{zwerg} \mid \text{SPAM})^1 \cdot P(\text{fressen} \mid \text{SPAM})^1 \cdot P(\text{ziege} \mid \text{SPAM})^0 \cdot P(\text{treten} \mid \text{SPAM})^0 \cdot P(\text{wolf} \mid \text{SPAM})^1 \cdot P(\text{bock} \mid \text{SPAM})^0 \cdot \mathbf{P}(\text{lecker} \mid \text{SPAM})^1$

Mapping:

- $P(\text{lecker} \mid \text{OK}) \rightarrow P(\text{UNK} \mid \text{OK}) = 0.043$
- $P(\text{lecker} \mid \text{SPAM}) \rightarrow P(\text{UNK} \mid \text{SPAM}) = 0.077$

Naive Bayes Training (Bernoulli NB, mit Laplace)

	sieben	zweig	fressen	ziege	treten	wolf	bock	Klasse
D1	1	1	1	1	0	0	0	OK
D2	1	0	0	1	1	1	0	SPAM
D3	1	0	1	0	0	1	1	OK
D4	1	1	0	0	1	0	1	OK

Klasse	sieben	zweig	fressen	ziege	treten	wolf	bock	Anzahl Dokumente
OK	3	2	2	1	1	1	2	3
SPAM	1	0	0	1	1	1	0	1

Naive Bayes Training (Bernoulli NB, mit Laplace), cnt.

Klasse	sieben	zwerg	fressen	ziege	treten	wolf	bock	Anzahl Dokumente
OK	3	2	2	1	1	1	2	3
SPAM	1	0	0	1	1	1	0	1

Naive Bayes "trainieren"

- A-priori-Wahrscheinlichkeit der Klassen:

$$P(c) = \frac{N_c}{N} = \frac{\text{Anzahl Dokumente in Klasse } c}{\text{Anzahl Dokumente}}$$

- Likelihood der Daten (Terme):

- $P(t = 1 | c) = \frac{\text{Anzahl Dokumente in Klasse } c \text{ mit Term } t + \alpha}{\text{Anzahl Dokumente in Klasse } c + 2 \cdot \alpha}$
- $P(t = 0 | c) = 1 - P(t = 1 | c)$

- A-priori-Wahrscheinlichkeit:

- $P(\text{OK}) = 3/4 = 0.75$
- $P(\text{SPAM}) = 1/4 = 0.25$

- Likelihood $\alpha = 1$:

- $P(\text{sieben} = 1 | \text{OK}) = (3 + 1)/(3 + 2) = 4/5 = 0.80$
- $P(\text{sieben} = 1 | \text{SPAM}) = (1 + 1)/(1 + 2) = 2/3 = 0.667$
- $P(\text{zwerg} = 1 | \text{OK}) = 3/5 = 0.60$
- $P(\text{zwerg} = 1 | \text{SPAM}) = 1/3 = 0.333$
- $P(\text{fressen} = 1 | \text{OK}) = 3/5 = 0.60$
- $P(\text{fressen} = 1 | \text{SPAM}) = 1/3 = 0.333$
- $P(\text{ziege} = 1 | \text{OK}) = 2/5 = 0.40$
- $P(\text{ziege} = 1 | \text{SPAM}) = 2/3 = 0.667$
- $P(\text{treten} = 1 | \text{OK}) = 2/5 = 0.40$

Naive Bayes Klassifikation (Bernoulli NB)

$$h_{MAP} = \operatorname{argmax}_{h \in H} P(h) \prod_{x \in \mathbf{x}} P(x \mid h)$$

Naive Bayes Klassifikation (Bernoulli NB)

$$h_{MAP} = \operatorname{argmax}_{h \in H} P(h) \prod_{x \in \mathbf{x}} P(x | h)$$

Für jedes Wort w im Vokabular V gibt es die Beobachtung (Bernoulli-Variable) $lw \in \{0, 1\}$.

$$h_{MAP} = \operatorname{argmax}_{h \in H} P(h) \prod_{w \in V} P(lw = 1 | h)^{lw} \cdot (1 - P(lw = 1 | h))^{1-lw}$$

T1: (sieben, zwerg, fressen, sieben, wolf)

- **h = OK:** $P(\text{OK}) \cdot P(\text{sieben} = 1 | \text{OK}) \cdot P(\text{zwerg} = 1 | \text{OK}) \cdot P(\text{fressen} = 1 | \text{OK}) \cdot P(\text{ziege} = 0 | \text{OK}) \cdot P(\text{treten} = 0 | \text{OK}) \cdot P(\text{wolf} = 1 | \text{OK}) \cdot P(\text{bock} = 0 | \text{OK})$
 $= 0.75 * 0.80 * 0.60 * 0.60 * (1 - 0.40) * (1 - 0.40) * 0.40 * (1 - 0.60) = 0.0124416$
- **h = SPAM:** $P(\text{SPAM}) \cdot P(\text{sieben} = 1 | \text{SPAM}) \cdot P(\text{zwerg} = 1 | \text{SPAM}) \cdot P(\text{fressen} = 1 | \text{SPAM}) \cdot P(\text{ziege} = 0 | \text{SPAM}) \cdot P(\text{treten} = 0 | \text{SPAM}) \cdot P(\text{wolf} = 1 | \text{SPAM}) \cdot P(\text{bock} = 0 | \text{SPAM})$
 $= 0.25 * 0.667 * 0.333 * 0.333 * (1 - 0.667) * (1 - 0.667) * 0.667 * (1 - 0.333) = 0.0009122091926$

Entscheidung: OK

Wrap-Up

- **Vorverarbeitung:** Tokenisierung, Vokabular, Bag of Words (BoW)

- **Multinomial NB:**

- Zähle die Vorkommen eines Terms:
$$P(t \mid c) = \frac{\text{count}(t, c) + \alpha}{\sum_{v \in V} \text{count}(v, c) + \alpha \cdot |V|}$$
- Klassifikation mit $h_{MAP} = \operatorname{argmax}_{h \in H} P(h) \prod_{w \in V} P(w \mid h)^{\text{count}(w)}$
- Im Test nicht vorhandene Terme t aus V werden ignoriert (Faktor 1)

- **Bernoulli NB:**

- Prüfe das Vorkommen eines Terms:
$$P(t = 1 \mid c) = \frac{\text{Anzahl Dokumente in Klasse } c \text{ mit Term } t + \alpha}{\text{Anzahl Dokumente in Klasse } c + 2 \cdot \alpha}$$
- Klassifikation mit $h_{MAP} = \operatorname{argmax}_{h \in H} P(h) \prod_{w \in V} P(lw = 1 \mid h)^{l_w} \cdot (1 - P(lw = 1 \mid h))^{1-l_w}$
- Im Test nicht vorhandene Terme t aus V werden korrekt mit $P(lw = 0 \mid h)$ berücksichtigt

- Problem mit kleinen Faktoren: **Logarithmus**, Übergang zu Summe
- **Zero-Frequency-Problem:** Laplace-Glättung mit $\alpha = 1$
- Klassifikation von **Out-of-Vocabulary-Termen:** UNK-Term trainieren



Unless otherwise noted, this work is licensed under CC BY-SA 4.0.

