NN08: Performanzanalyse

Canan Yıldız (Türkisch-Deutsche Universität)

Videos

- NN8.1 - Confusion Matrix
- NN8.2 - Precision und Recall
- NN8.3 - Precision Recall Trade-off
- NN8.4 - F1-Score
- NN8.5 - Harmonisches Mittel- Intuition

Weitere Unterlagen

- NN08-Performanzanalyse.pdf

1 Kurze Übersicht

1.1 Performanzmetriken für Klassifizierungsprobleme

1.1.1 Wahrheitsmatrix (engl. Confusion Matrix)

- Gibt eine Übersicht über die Anzahl von richtig und falsch klassifizierten Datenpunkten (bei binärer Klassifizierung)
  - $TP =$ # True Positives $=$ Anzahl richtiger 1-Vorhersagen
  - $FP =$ # False Positives $=$ Anzahl falscher 1-Vorhersagen
  - $FN =$ # False Negatives $=$ Anzahl falscher 0-Vorhersagen
  - $TN =$ # True Negatives $=$ Anzahl richtiger 0-Vorhersagen
- Bei Klassifizierungsproblemen mit N Klassen hat man eine $N \times N$ Matrix, die in Position (i, j) die Anzahl der Klasse-j-Beispiele enthält, die als Klasse-i vorhergesagt wurden.

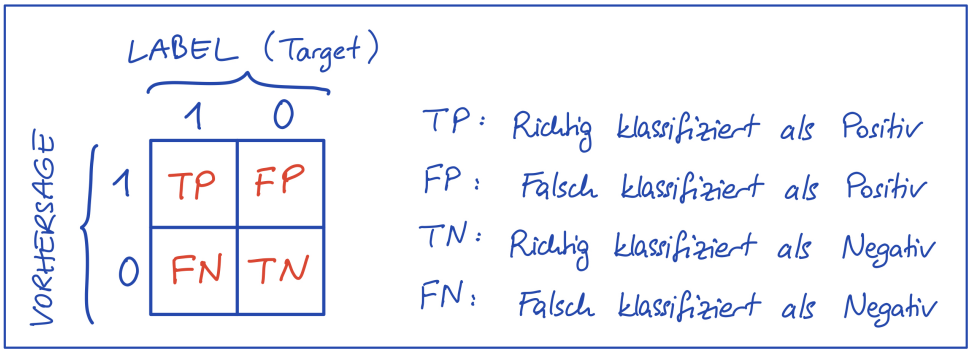

Abbildung 1: Abbildung 1 - Wahrheitsmatrix bei binärer Klassifizierung

1.1.2 Treffergenauigkeit (engl. Accuracy)

- Anzahl richtig klassifizierter Datenpunkte, Erfolgsrate (engl. correct rate)

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN}$$

- Accuracy vermittelt ein falsches Bild des Erfolges bei unausgewogenen Datensätzen

  Beispiel:

  - Klasse 1 hat 10, Klasse 0 hat 990 Beispiele.
  - Ein Modell, das immer 0 ausgibt, hat $990/1000 = 0.99$ Treffergenauigkeit, ist aber offensichtlich kein gutes Modell!

1.1.3 Precision

- Positive Predictive Value (PPV)
- Antwort auf: Von allen **positiven Vorhersagen**, wie viele sind richtig?

$$Precision = \frac{TP}{TP + FP}$$

- Wahrscheinlichkeit, dass ein positiv klassifiziertes Beispiel auch tatsächlich positiv ist.
- Je näher an 1, desto besser.
- Accuracy of **positive predictions**.

1.1.4 Recall

- True Positive Rate, auch Sensitivität (engl. Sensitivity)
- Antwort auf: Von allen **positiven Beispielen**, wie viele wurden richtig klassifiziert?

$$Recall = \frac{TP}{TP + FN}$$

- Wahrscheinlichkeit, dass ein positives Beispiel tatsächlich als solches erkannt wird.
- Je näher an 1, desto besser.
- Accuracy of **positive examples**.

1.1.5 Precision-Recall Trade-off

- Ein gutes Modell sollte hohe Precision und zugleich hohes Recall haben.
- Man kann die Precision eines Modells beliebig erhöhen (durch das Vergrößern des Schwellenwertes bei der Klassifizierung), jedoch wird dabei der Recall abnehmen.
- Genau so kann man den Recall eines Modells beliebig erhöhen (durch das Verkleinern des Schwellenwertes bei der Klassifizierung), jedoch wird dabei die Precision abnehmen.

- Es gilt ein gutes Trade-off zu finden.
- Eine Zwei-Zahlen-Metrik erschwert den Entscheidungsprozess bei Evaluierung und Modellauswahl.

1.1.6 F_1-Score (Harmonisches Mittel)

- Fasst Precision (P) und Recall (R) in einer Metrik zusammen (Harmonisches Mittel von P und R):

$$F_1 - Score = \frac{2}{\frac{1}{P} + \frac{1}{R}} = 2 \cdot \frac{PR}{P + R}$$

- Der F_1-Score wird nur dann hoch sein, wenn P und R beide hoch sind.
- Je näher an 1, desto besser.
- Sehr kleine P und R Werte ziehen den F_1-Score sehr stark herunter. In dieser Hinsicht gibt diese Metrik ein akkurates Bild über den Erfolg eines Modells.

Lernziele

- k2: Ich kann die betrachteten Performanzmetriken für die Evaluierung von Klassifizierungsmodellen erläutern
- k2: Ich kann die Wahrheitsmatrix (engl. Confusion Matrix) erklären
- k2: Ich kann den Begriff Treffergenauigkeit (engl. Accuracy) erklären
- k2: Ich kann den Begriff Precision (engl. Precision) erklären
- k2: Ich kann den Begriff Recall erklären
- k2: Ich kann den Begriff F_1-Score (Harmonisches Mittel) erklären
- k3: Ich kann Precision und Recall berechnen und deuten
- k3: Ich kann den F_1-Score berechnen und deuten
- k3: Ich kann die Performanzmetriken bei der Evaluierung und Auswahl von Modellen einsetzen

Unless otherwise noted, this work is licensed under CC BY-SA 4.0.

> **Last modified:** 9a4d8be (lecture: add NN to title (NN), 2025-08-29)